

Conception et évaluation d'un assistant IA juridique : étude comparative entre RAG et fine-tuning

Compte Rendu - Semaine 1



Auteur

Bartosz Konior
M1 DSC, Year 1

Encadrant : François Jacquenet

Date : 30 avril 2026

Travail Réalisé durant la Semaine 1 (27–30 avril 2026)

Coordination avec Chaabane Ouammou

Nous avons convenu de nous réunir en début de chaque semaine. Nous prévoyons de travailler fréquemment ensemble, notamment en début de projet, et ces réunions pourraient avoir lieu plus d'une fois par semaine selon les besoins.

Cette première semaine, une réunion n'a pas pu avoir lieu en raison d'indisponibilités. Nous avons néanmoins décidé de nous répartir les premières lectures : je me suis concentré sur les approches de fine-tuning et de RAG, afin de pouvoir échanger et consolider nos connaissances lors de notre prochaine rencontre.

Revue bibliographique

Conformément aux consignes, un premier effort de lecture a été consacré au projet. En parallèle des articles présentés ci-dessus, j'en ai repéré plusieurs autres que je souhaiterais approfondir dans les prochaines semaines. Certains étant assez complexes, leur compréhension demande un peu de temps, c'est pourquoi je les ai pour l'instant simplement ajoutés en références. Si vous avez d'autres articles à me conseiller, je suis bien entendu preneur, cela m'aiderait à mieux orienter mes lectures.

Fine-Tuning

- **Hu et al. (2022)**, *LoRA: Low-Rank Adaptation of Large Language Models* [1] — arXiv:2106.09685
- **Dettmers et al. (2023)**, *QLoRA: Efficient Finetuning of Quantized LLMs* [2] — arXiv:2305.14314

Retrieval-Augmented Generation (RAG)

- **Lewis et al. (2020)**, *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks* [3] — arXiv:2005.11401
- Ressources vidéo complémentaires : YouTube 1, YouTube 2, YouTube 3

Comparaison RAG / Fine-Tuning

- **Bouvard, Ciancone, Gourru, Schaeffer (2024)**, *Derby LLM : Évaluation comparative des approches RAG et fine-tuning* [4] — hal-04638460

Exploration des ressources

Un premier travail exploratoire a été initié concernant les benchmarks disponibles, les datasets existants et les ressources liées au domaine juridique. Il s'agit pour l'instant d'une phase de repérage : aucune décision définitive n'a encore été prise, car ces choix requièrent du temps de recherche et de discussion. Ce travail va faire partie de la semaine 2.

References

- [1] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, W. Chen. *LoRA: Low-Rank Adaptation of Large Language Models*. ICLR 2022. arXiv:2106.09685
- [2] T. Dettmers, A. Pagnoni, A. Holtzman, L. Zettlemoyer. *QLoRA: Efficient Finetuning of Quantized LLMs*. NeurIPS 2023. arXiv:2305.14314

- [3] P. Lewis, E. Perez, A. Piktus et al. *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*. NeurIPS 2020. [arXiv:2005.11401](#)
- [4] C. Bouvard, M. Ciancone, A. Gourru, M. Schaeffer. *Derby LLM : Évaluation comparative des approches RAG et fine-tuning*. APIA-2024, PFIA, La Rochelle, 2024. [hal-04638460](#)
- [5] M. A. de Luis Balaguer, V. Benara, R. L. de Freitas Cunha et al. *RAG vs Fine-Tuning: Pipelines, Tradeoffs, and a Case Study on Agriculture*. [arXiv:2401.08406](#), 2024.
- [6] I. Chalkidis, M. Fergadiotis, P. Malakasiotis, N. Aletras, I. Androutopoulos. *LEGAL-BERT: The Muppets straight out of Law School*. Findings of EMNLP 2020. [arXiv:2010.02559](#)
- [7] N. Guha, J. Nyarko, D. E. Ho et al. *LegalBench: A Collaboratively Built Benchmark for Measuring Legal Reasoning in Large Language Models*. NeurIPS 2023. [arXiv:2308.11462](#)
- [8] A. Pipitone, R. Alami. *LegalBenchRAG: Benchmarking Retrieval-Augmented Generation for Legal Questions*. [arXiv:2408.10343](#), 2024.
- [9] M. Dahl, V. Magesh, M. Suzgun, D. E. Ho. *Large Legal Fictions: Profiling Legal Hallucinations in Large Language Models*. Journal of Legal Analysis, 2024. [arXiv:2401.01301](#)