

Université Jean Monnet Saint-Étienne
TER - S2 2025/2026

Conception et évaluation d'un assistant IA juridique : étude comparative entre RAG et fine-tuning

Compte Rendu

Auteur

Bartosz Konior
M1 DSC, Year 1

Encadrant : François Jacquenet

Date : 10 juillet 2026

Progression

Cette semaine j'ai testé la dernière configuration qui manquait au tableau comparatif : le modèle fine-tuné combiné au RAG, c'est-à-dire qu'on lui donne en plus le contexte récupéré par la recherche avant de générer sa réponse. L'idée était de voir si les deux approches se cumulent vraiment ou si l'une prend le dessus sur l'autre.

Techniquement, il a juste fallu brancher les deux bouts déjà existants : le retrieval d'un côté, le modèle fine-tuné de l'autre, au lieu de Mistral de base. Rien de compliqué en soi, mais le prompt final est plus long (contexte + question), donc l'inférence est un peu plus lente et j'ai dû réduire le nombre de fragments injectés pour ne pas saturer le GPU gratuit.

J'ai aussi commencé l'analyse des erreurs sur les réponses générées. Pour l'instant je regarde surtout les cas où le modèle hallucine un article qui n'existe pas, et ceux où il répond alors qu'il aurait dû dire qu'il ne savait pas. C'est encore préliminaire, je compte catégoriser ça plus proprement dans les prochaines semaines.

Réunion avec Chaabane

On a pris un moment cette semaine pour faire le point ensemble sur où en est le projet et sur comment mieux le tester. Un des constats qu'on a fait, c'est que pour l'instant le système se contente surtout de retrouver un article pertinent, alors qu'on voudrait vraiment une réponse rédigée et claire qui cite l'article en source, plutôt que juste l'article brut. On en a discuté et il faut qu'on retravaille le prompt de génération pour forcer ce format (réponse en langage naturel + référence précise à l'article utilisé), à la fois pour le RAG et pour le modèle fine-tuné.

On a aussi parlé de comment mieux évaluer ce qu'on a déjà : les métriques actuelles (ROUGE-L, BERTScore) disent si la réponse ressemble à la référence, mais pas si la source citée est la bonne. On veut ajouter une vérification simple qui compare l'article cité par le modèle à l'article qui aurait dû être utilisé, ce qui donnerait une mesure plus directe de la fiabilité des réponses.