

Université Jean Monnet Saint-Étienne
TER - S2 2025/2026

Conception et évaluation d'un assistant IA juridique : étude comparative entre RAG et fine-tuning

Compte Rendu

Auteur

Bartosz Konior
M1 DSC, Year 1

Encadrant : François Jacquenet

Date : 3 juillet 2026

Période : 6 juin – 3 juillet 2026

Organisation

Cette période a été marquée par une interruption du 9 au 17 juin due à des vacances. Le travail a repris le 18 juin et s'est concentré sur l'amélioration du système RAG, une deuxième itération de fine-tuning, et l'évaluation comparative des quatre configurations du système.

Travail réalisé par Chaabane pendant mon absence

Pendant mon interruption, Chaabane a poursuivi seul le travail, notamment l'évaluation du RAG de référence et le premier entraînement QLoRA. Cette section résume ces résultats afin de faire le lien entre le compte-rendu du dernier rapport et la suite de ce rapport, qui présente directement des améliorations par rapport à ces premières itérations.

Évaluation du RAG de référence

Chaabane a terminé l'évaluation du retrieval sur les 222 questions du jeu de test, avec un modèle d'embeddings généraliste mis en place initialement (avant le remplacement par multilingual-e5-large). Les résultats obtenus sont les suivants :

Métrique	Ancien modèle
Top 1 résultat (Recall@1)	12 questions / 100
Top 3 résultats (Recall@3)	20 questions / 100
Top 5 résultats (Recall@5)	26 questions / 100
Top 10 résultats (Recall@10)	35 questions / 100
ROUGE-L (génération)	0.1535

TABLE 1 – Baseline RAG obtenue par Chaabane sur les 222 questions test

Ces chiffres correspondent à la colonne « Ancien modèle » reprise dans le tableau comparatif de la section suivante.

Première itération de fine-tuning

En parallèle, Chaabane a lancé et évalué le premier entraînement QLoRA (r=16, quantification 4-bit NF4) sur les 380 exemples de questions-réponses issus de BSARD, sur Mistral-7B. Les résultats sont :

Configuration	ROUGE-L	BERTScore
Première itération (380 exemples)	0.1375	0.6814

TABLE 2 – Résultats du premier entraînement QLoRA (50 questions test)

Ces résultats constituent également la ligne de référence « Première itération » (prochaine section) comparée à la deuxième itération réalisée après mon retour.

Amélioration de la recherche d'articles

Problème initial

Lors de l'évaluation précédente (menée par Chaabane), le système RAG retrouvait le bon article dans seulement 35 questions sur 100. Autrement dit, dans 65 cas sur 100, le bon article n'était pas parmi les résultats proposés au modèle, ce qui rendait toute génération correcte impossible pour ces questions.

Solution testée

Nous avons remplacé le modèle de recherche par un modèle plus récent et plus performant. Le nouveau modèle s'appelle multilingual-e5-large. Contrairement au précédent, il a été entraîné sur un corpus plus large et produit des représentations plus précises du sens des phrases.

Résultats

Le gain est significatif. Le tableau ci-dessous montre combien de questions ont leur bon article retrouvé selon le nombre de résultats considérés.

	Ancien modèle	Nouveau modèle
Top 1 résultat	12 questions / 100	20 questions / 100
Top 3 résultats	20 questions / 100	35 questions / 100
Top 5 résultats	26 questions / 100	42 questions / 100
Top 10 résultats	35 questions / 100	52 questions / 100

TABLE 3 – Nombre de questions pour lesquelles le bon article est retrouvé (sur 222 questions test)

Avec le nouveau modèle, le bon article est présent dans les 10 premiers résultats pour plus d'une question sur deux. C'est une bonne amélioration.

Deuxième itération de fine-tuning

Ce qui a changé

Le premier entraînement utilisait 380 exemples de questions et réponses. Pour cette deuxième itération, nous en avons ajouté 200 supplémentaires en utilisant des questions générées automatiquement par le dataset BSARD, filtrées manuellement pour écarter les moins pertinentes. Le modèle a donc appris sur 580 exemples au total. La capacité du modèle a été également augmentée pour lui permettre de mieux s'adapter au domaine juridique.

Résultats

Configuration	ROUGE-L	BERTScore
Première itération (380 exemples)	0.1375	0.6814
Deuxième itération (580 exemples)	0.1612	0.7043

TABLE 4 – Comparaison des deux itérations de fine-tuning (50 questions test)

Pour expliquer ces métriques simplement : le ROUGE-L mesure si les mots de la réponse générée sont les mêmes que dans la réponse de référence. Le BERTScore mesure si le sens général est proche, même si les mots exacts diffèrent. Un score plus élevé est toujours meilleur. On observe une amélioration modeste mais cohérente avec l'ajout de données.

Comparaison des configurations

Nous avons évalué trois versions du système sur les mêmes 50 questions afin de mesurer l'apport de chaque approche.

Configuration	ROUGE-L	BERTScore
Mistral seul, sans adaptation	0.0821	0.6112
RAG seul (recherche + Mistral de base)	0.1535	0.6589
Fine-tuning seul (sans recherche)	0.1612	0.7043

TABLE 5 – Comparaison des configurations (50 questions test)

Les résultats sont clairs. Mistral sans aucune adaptation donne les moins bonnes réponses. Le RAG et le fine-tuning pris séparément donnent des résultats proches. On devrait comparer sur plus de questions et essayer de combiner RAG avec le fine-tuning. La combinaison des deux devrait donner les meilleurs résultats sur les deux métriques, ce qui suggère que ces deux approches sont complémentaires plutôt que concurrentes.

Difficultés

L'indexation du corpus avec le nouveau modèle de recherche a pris plus de 2h sur le GPU gratuit de Colab en raison de la taille plus importante du modèle. La gestion du quota GPU a aussi contraint à alterner entre Colab et Kaggle pour éviter les interruptions.