

Université Jean Monnet Saint-Étienne
TER - S2 2025/2026

Conception et évaluation d'un assistant IA juridique : étude comparative entre RAG et fine-tuning

Compte Rendu

Auteur

Bartosz Konior
M1 DSC, Year 1

Encadrant : François Jacquenet

Date : 24 juillet 2026

Organisation

Ces deux semaines ont été entièrement consacrées à l'évaluation comparative des quatre configurations du système (Mistral seul, RAG, fine-tuning, fine-tuning + RAG) sur l'ensemble du jeu de test, ainsi qu'à la mise en place d'une métrique de citation.

Reformulation du prompt de génération

Comme discuté lors de notre point de la semaine dernière, nous avons retravaillé le prompt de génération pour forcer le format attendu : une réponse rédigée en langage naturel suivie d'une citation précise de l'article utilisé (par exemple « Article 1240 du Code civil »), plutôt que la simple restitution du fragment brut. Ce nouveau prompt a été appliqué aux quatre configurations pour garder la comparaison équitable. Le changement a nettement réduit les cas où le modèle se contentait de recopier l'article sans reformulation, mais a légèrement allongé les temps de génération.

Mise en place de la métrique de citation

Nous avons implémenté la vérification simple envisagée la semaine dernière : pour chaque réponse, on extrait l'identifiant d'article cité (via une expression régulière sur le numéro d'article et le code concerné) et on le compare à l'article de référence attendu pour la question. On obtient ainsi un score d'« exactitude de citation », calculé comme le pourcentage de questions où l'article cité correspond exactement à l'article attendu. Cette métrique, contrairement au ROUGE-L et au BERTScore, ne mesure pas la ressemblance textuelle mais directement la fiabilité de la source invoquée, ce qui correspond mieux à notre question de recherche.

Analyse d'erreurs

Nous avons catégorisé manuellement les erreurs sur un échantillon de 40 questions par configuration. Deux catégories principales ressortent :

- **Hallucination d'article** : le modèle cite un numéro d'article qui n'existe pas ou qui ne correspond à aucun texte du corpus. Cette erreur est nettement plus fréquente en fine-tuning seul.
- **Confusion entre systèmes juridiques** : le modèle mélange des notions de droit français avec des règles issues d'autres systèmes juridiques (observé surtout sur Mistral seul, sans adaptation).