Université Jean Monnet Saint-Étienne
TER. Année 2025/2026

Assistant juridique fondé sur l'IA
RAG contre fine-tuning, une comparaison expérimentale

Rapport final de TER

Chaabane Ouammou , M1 MLDM *co-auteur* **Bartosz Konior**, M1 DSC

Résumé

Ce rapport compare deux façons d'adapter un grand modèle de langage à un domaine spécialisé, la génération augmentée de récupération (RAG) et le fine-tuning paramétriquement efficace (QLoRA). Le domaine choisi est le droit, un terrain exigeant où une réponse fausse ou une citation inventée a un coût réel. Nous construisons un assistant de question-réponse juridique en français, évalué sur BSARD, un corpus de droit belge francophone, avec le modèle Mistral-7B-Instruct. Quatre configurations sont comparées sur 222 questions de test, sans adaptation, avec RAG seul, avec fine-tuning seul, et avec les deux combinés. La qualité des réponses est mesurée par des métriques automatiques (ROUGE-L, BERTScore, exactitude de citation, taux d'hallucination), par un jugement automatique complémentaire (juge LLM, fidélité) et par une évaluation humaine à l'aveugle. Le RAG et le fine-tuning apportent chacun un gain net par rapport à l'absence d'adaptation, et les combiner fait encore mieux en moyenne. Mais aucune des deux techniques ne résout à elle seule le problème le plus sérieux constaté, à savoir que le système invente des références juridiques avec assurance plutôt que de reconnaître ses limites.

1. Introduction

Un grand modèle de langage sait aujourd'hui rédiger un texte fluide sur à peu près n'importe quel sujet, mais ses connaissances restent celles de ses données d'entraînement, généralistes, souvent en anglais, et figées à une date donnée. Dès qu'on veut l'utiliser sur un domaine précis et exigeant se pose la question de savoir comment lui donner accès à des connaissances qu'il ne possède pas nativement. Deux familles de réponses techniques dominent la littérature et la pratique. Le fine-tuning réentraîne partiellement le modèle sur des données du domaine. La génération augmentée de récupération, ou RAG, laisse le modèle intact mais lui fournit au moment de répondre des extraits de documents pertinents retrouvés dans une base externe. Ces deux familles ne sont pas seulement deux implémentations différentes du même objectif. Elles ne font pas le même choix sur l'endroit où stocker cette connaissance nouvelle. Le fine-tuning la place directement dans les poids du modèle, tandis que le RAG la garde à l'extérieur, dans une base qu'on consulte au moment de répondre. C'est cette différence de principe qui justifie de comparer les deux plutôt que d'en choisir une par habitude. Cette différence n'est pas qu'académique. Une base documentaire externe se met à jour en changeant simplement les documents indexés, tandis qu'un modèle fine-tuné doit être réentraîné dès que le droit change, ce qui a un coût opérationnel très différent selon la technique retenue.

Ce travail compare expérimentalement ces deux approches sur un cas d'usage concret, un assistant capable de répondre à des questions de droit en français en citant l'article de loi sur lequel il s'appuie. Trois questions de recherche guident l'ensemble du travail.

1. Un modèle spécialisé par fine-tuning, même entraîné sur peu d'exemples, peut-il rivaliser avec un modèle généraliste appuyé sur une recherche documentaire externe ?
2. Dans quels cas le fine-tuning apporte-t-il un gain réel par rapport au RAG seul, et ce gain se maintient-il une fois combiné avec le RAG ?
3. Le système sait-il citer sa source de façon fiable, et reconnaît-il ses propres limites lorsqu'il ne peut pas répondre correctement ?

1.1 Pourquoi le droit

Choisir le droit comme terrain d'expérimentation n'est pas arbitraire. Une réponse juridique approximative n'est pas seulement moins utile qu'une réponse précise, elle peut activement induire en erreur une personne qui s'appuie dessus pour une décision réelle, ce qui donne un poids concret à la question de la fiabilité. La traçabilité de la source est aussi une exigence du domaine lui-même plutôt qu'une contrainte ajoutée artificiellement. Une réponse juridique crédible s'appuie sur un texte de loi identifiable, ce qui donne un signal de fiabilité mesurable (la référence citée existe-t-elle vraiment, et est-elle la bonne) là où beaucoup d'autres domaines n'offrent qu'un jugement de qualité subjectif. Enfin, la structure hiérarchique du texte de loi, code, livre, titre, chapitre, article, se prête naturellement au découpage par unité citable, ce qui en fait un bon cas d'usage pour le RAG.

D'autres domaines candidats ont été écartés pour des raisons pratiques plutôt que théoriques. Le domaine

médical partage plusieurs de ces propriétés mais l'accès à des données réelles y est fortement restreint pour des raisons de confidentialité. La disponibilité de corpus juridiques francophones librement accessibles (section 3), a fixé le choix du domaine avant même de commencer les expériences.

Le reste du rapport présente le contexte institutionnel du projet, passe en revue l'état de l'art qui a guidé nos choix, décrit notre contribution méthodologique, présente l'ensemble des résultats obtenus, puis conclut en répondant aux trois questions ci-dessus.

2. Contexte du projet

Ce travail est un TER, travail d'étude et de recherche, mené en binôme à l'université Jean Monnet de Saint-Étienne.

Le sujet compare le RAG et le fine-tuning sur un cas d'usage concret. Tout le calcul GPU a été réalisé sur Kaggle, avec une carte graphique Tesla T4. Cette contrainte a directement déterminé des choix méthodologiques décrits plus loin, la taille des jeux d'entraînement de fine-tuning et le choix d'un modèle de 7 milliards de paramètres.

3. État de l'art

3.1 Adaptation efficace des grands modèles de langage

Le fine-tuning complet d'un LLM de plusieurs milliards de paramètres est coûteux en mémoire et en temps de calcul, ce qui a motivé le développement de méthodes de fine-tuning paramétriquement efficaces (parameter-efficient fine-tuning, PEFT). LoRA [10] propose de geler les poids du modèle pré-entraîné et d'ajouter, à côté de certaines matrices (typiquement celles de l'attention), une paire de matrices de rang faible dont le produit approxime la mise à jour qu'aurait produite un fine-tuning complet

$$W' = W_0 + BA,$$

avec W_0 la matrice originale gelée, B de taille $d \times r$, A de taille $r \times k$, et le rang r choisi bien plus petit que d ou k. Le nombre de paramètres entraînables devient ainsi une toute petite fraction du modèle total. QLoRA [6] pousse cette idée plus loin en quantifiant le modèle de base en 4 bits (format NF4) avant d'y greffer les adaptateurs LoRA, ce qui réduit fortement l'empreinte mémoire et permet d'entraîner un modèle de 7 milliards de paramètres sur un unique GPU grand public. Les poids quantifiés restent gelés pendant tout l'entraînement, seuls les adaptateurs sont mis à jour, ce qui évite d'avoir à stocker des gradients et un état d'optimiseur pour l'intégralité du modèle. C'est cette approche que nous utilisons (section 4.4).

3.2 Génération augmentée de récupération

Le RAG couple un modèle de recherche documentaire à un modèle génératif. Au moment de répondre, les passages les plus pertinents d'une base documentaire sont retrouvés puis injectés dans le contexte fourni au générateur, ce qui évite de réentraîner le modèle à chaque mise à jour de la base et permet en principe de citer explicitement la source utilisée. La recherche documentaire s'appuie soit sur des représentations denses obtenues par un modèle d'embedding [12], soit sur des méthodes lexicales comme BM25, soit sur une combinaison des deux. BM25 note un document en fonction de la fréquence des mots de la question qu'il contient, pondérée par leur rareté dans l'ensemble du corpus, ce qui le rend très efficace sur des termes exacts mais aveugle aux synonymes. Les deux signaux peuvent être combinés par fusion de rang réciproque, qui attribue à chaque document un score

$$\mathrm{RRF}(d) = \sum_i \frac{1}{k + \mathrm{rang}_i(d)},$$

la somme portant sur les classements produits par chaque méthode et k une constante qui atténue le poids des rangs les plus bas, de sorte qu'un document bien classé par au moins une méthode remonte dans le classement final même s'il est absent de l'autre. Deux textes denses sont comparés par similarité cosinus entre leurs vecteurs

$$\mathrm{sim}(q, d) = \frac{q \cdot d}{\|q\| \, \|d\|},$$

ce qui rapproche des textes sémantiquement proches même quand ils partagent peu de mots exacts, une propriété qu'une méthode purement lexicale n'a pas. Notre propre pipeline, un RAG dit naïf plutôt qu'une variante avancée, est décrit en section 4.3.

3.3 Comparaisons existantes entre RAG et fine-tuning

Notre travail se positionne directement par rapport à l'étude Derby LLM de Bouvard, Ciancone, Gourru et Schaeffer [2]. Cette étude compare RAG et fine-tuning sur deux corpus d'entreprise français, avec le même modèle de base que nous, Mistral 7B. Leur fine-tuning procède par poursuite du pré-entraînement, c'est-à-dire une continuation de la tâche de prédiction du prochain mot directement sur les documents du domaine, sans reformulation en paires question-réponse, tandis que leur RAG s'appuie sur une solution commerciale et sur des embeddings OpenAI. Leur conclusion principale est nette, le RAG est très largement préféré par les annotateurs humains (autour de 67 % contre 3 % pour le fine-tuning selon le jeu de données), et le fine-tuning par poursuite du pré-entraînement peine à injecter des connaissances nouvelles de manière fiable.

Notre protocole reprend délibérément les mêmes familles de métriques (arène par paires, fidélité par recouvrement d'entités) pour permettre une comparaison directe, mais s'en distingue sur un point important, notre fine-tuning est supervisé sur des paires question-réponse formatées avec citation d'article, et non une poursuite non supervisée du pré-entraînement. Cette distinction rejoint les travaux d'Ovadia et al. [18], qui montrent que le RAG surpasse systématiquement le fine-tuning non

supervisé pour l'injection de connaissances factuelles, exactement la limite rencontrée avec ce fine-tuning par poursuite du pré-entraînement. En testant un fine-tuning supervisé, plus proche de l'usage pour lequel QLoRA a été conçu, nous vérifions si cette limite tient encore.

3.4 Évaluer un système de question-réponse génératif

L'évaluation d'un texte généré par un LLM reste un problème ouvert, et plusieurs familles de méthodes coexistent, chacune avec ses limites propres. Les métriques de similarité de surface comme ROUGE [14] comptent le recouvrement de sous-séquences de mots entre un texte généré et une référence. Elles sont rapides et reproductibles mais pénalisent injustement une reformulation correcte qui n'utilise pas les mêmes mots. BERTScore [20] corrige partiellement ce défaut en comparant des représentations contextuelles plutôt que des chaînes exactes, au prix d'un calcul plus coûteux. Des outils plus récents comme RAGAS [7] évaluent spécifiquement les systèmes RAG en décomposant la qualité en plusieurs facettes, généralement en confiant à un LLM l'extraction puis la vérification d'affirmations individuelles.

L'évaluation humaine par comparaison directe de paires de réponses donne un signal plus proche de l'usage réel mais reste coûteuse à collecter et sujette à un accord inter-annotateurs imparfait, qui doit lui-même être mesuré plutôt que supposé. Le modèle de Bradley-Terry, associé à cette méthode, transforme un ensemble de votes par paires en un score de force relative sur une échelle unique, et nous le réutilisons pour notre propre arène (section 5.7). Enfin, utiliser un grand modèle de langage comme juge introduit des biais documentés, en particulier un biais d'auto-préférence lorsque le juge est aussi l'un des systèmes évalués, un point que nous avons pris soin d'éviter dans notre protocole en choisissant un juge extérieur aux configurations comparées (section 5.7).

3.5 Corpus, bancs d'essai et modèles de base

Plusieurs bancs d'essai juridiques existent dans la littérature, essentiellement en anglais. LegalBench [8] rassemble une collection de tâches de raisonnement juridique construites collaborativement, CUAD [9] porte sur l'analyse de contrats, et LexGLUE [3] propose un ensemble de tâches de compréhension du langage juridique. Pour le français, BSARD [15] propose un corpus de recherche d'articles de loi belges francophones, décrit en détail en section 4.1. Son prolongement naturel, LLeQA [16], ajoute des réponses rédigées sur ce même corpus, et était notre cible initiale, mais l'accès n'a jamais été accordé malgré une demande, ce qui a justifié la bascule vers BSARD. Cette bascule a une conséquence directe sur l'évaluation, discutée en section 4.1, un corpus de recherche documentaire ne fournit pas de réponse rédigée de référence, contrairement à ce qu'aurait offert LLeQA, ce qui nous a obligés à reconstruire cette référence nous-mêmes plutôt que de pouvoir nous appuyer sur une rédaction humaine déjà existante.

Côté modèles, nous utilisons Mistral-7B-Instruct [11], un modèle ouvert qui offre un bon compromis entre qualité et coût d'exécution. Nous testons également la généralisation de nos observations à Qwen2.5-7B-Instruct (section 5.3), un modèle de taille comparable mais entraîné sur un mélange de données différent, ce qui en fait un point de comparaison indépendant plutôt qu'une simple variante du même modèle. Tous ces modèles reposent sur l'architecture Transformer [19] et sont alignés par instruction-tuning à la suite d'InstructGPT [17], une étape qui les entraîne à suivre une consigne plutôt qu'à simplement continuer un texte, et qui explique pourquoi ils peuvent être interrogés directement avec une question sans exemples préalables.

4. Contribution méthodologique

4.1 Données

BSARD (Belgian Statutory Article Retrieval Dataset) [15] est un corpus public de droit belge francophone, composé de 22 633 articles de loi et de questions annotées avec les identifiants des articles nécessaires pour y répondre. Le corpus fournit un split d'entraînement de 886 questions et un split de test de 222 questions, que nous utilisons dans leur totalité plutôt que sur un sous-échantillon, précisément pour que nos conclusions ne dépendent pas d'un tirage particulier. Chaque question porte un champ de catégorie juridique parmi sept valeurs (figure 1), dont la répartition est fortement déséquilibrée, Famille et Logement dominent largement tandis que Protection sociale ne compte que quatre questions dans le jeu de test, une limite qu'il faut garder en tête en lisant les résultats par catégorie (section 5.5).

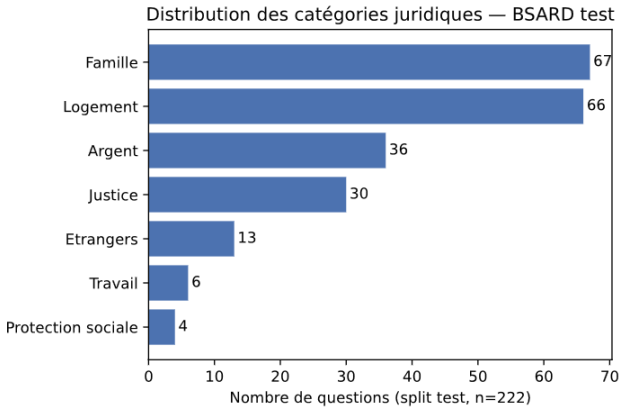


FIGURE 1. Répartition des questions de test BSARD par catégorie juridique.

Le choix du droit belge francophone plutôt que du droit français mérite d'être justifié. L'objet de ce travail est la comparaison de méthodes d'adaptation d'un modèle à un domaine, pas le contenu juridique français en tant que tel. La langue reste le français, la structure du problème (citer un article de loi précis pour répondre) est identique, et le blocage de l'accès à LLeQA rend BSARD le meilleur substitut disponible librement.

Une limite méthodologique doit être assumée explicitement. BSARD est nativement un corpus de recherche documentaire et non de question-réponse générative, il ne contient aucune réponse rédigée en langage naturel, seulement les identifiants des articles pertinents. La réponse de référence utilisée pour calculer ROUGE-L et BERTScore est donc reconstruite par concaténation du texte des articles cités, ce qui n'est pas une réponse idéale telle qu'un juriste l'aurait rédigée. Les scores de similarité de surface présentés plus loin doivent donc être lus comme une mesure de recouvrement lexical avec le texte de loi, pas comme une mesure de qualité rédactionnelle. Cette limite explique en grande partie pourquoi tous les scores ROUGE-L observés dans ce rapport restent relativement bas, sans que cela signifie que les réponses soient inutilisables.

4.2 Quatre configurations comparées

Nous comparons quatre configurations, résumées dans le tableau 1. Le même prompt système, en français, est utilisé dans les quatre cas pour garantir une comparaison équitable. Il demande une réponse claire et rédigée, appuyée sur le contexte fourni le cas échéant, se terminant impérativement par une citation au format « Article <numéro> », et invite explicitement le modèle à répondre « Je ne sais pas » plutôt que d'inventer une réponse s'il n'a pas assez d'éléments.

TABLE 1. Description des quatre configurations comparées.

Config	Retrieval	Fine-tuning
C1 zero-shot	non	non
C2 RAG	oui	non
C3 fine-tune	non	oui
C4 fine-tune + RAG	oui	oui

4.3 Pipeline de recherche documentaire

La recherche documentaire combine un index dense, construit avec le modèle multilingue *multilingual-e5-large*, et un index lexical BM25, fusionnés par fusion de rang réciproque. Un rerankeur à cross-encodeur, *bge-reranker-v2-m3* [4], réordonne ensuite les candidats retrouvés. Par défaut, les cinq articles les mieux classés sont injectés dans le prompt du générateur. Ce choix de pipeline en deux étapes (recherche puis reclassement) vient directement de l'état de l'art (section 3.2), mais sa contribution réelle sur notre corpus n'était pas acquise à l'avance, ce qui justifie l'ablation dédiée de la section 5.1.

4.4 Fine-tuning QLoRA

Un fine-tuning complet de Mistral-7B en précision standard nécessiterait de stocker le modèle, ses gradients et l'état de l'optimiseur, soit largement plus de mémoire que ce qu'offre un GPU grand public. QLoRA contourne ce mur en gardant le modèle de base en 4 bits pendant tout l'entraînement et en ne calculant des gradients que pour les petites matrices B et A ajoutées par LoRA, ce qui rend possible l'entraînement sur un T4.

Concrètement, le fine-tuning gèle le modèle de base, quantifié en 4 bits, et entraîne un adaptateur LoRA de rang 32 sur les matrices d'attention, soit environ 0,375 % des paramètres totaux du modèle. Ce rang n'a pas été fixé arbitrairement, il a été retenu après comparaison avec un rang plus faible (section 5.6), qui donne un gain net mais modeste pour un coût de calcul nettement plus élevé. L'entraînement principal utilise 580 exemples question-réponse-citation construits à partir du split d'entraînement de BSARD, sur trois époques, avec un taux d'apprentissage de 2×10^{-4}. Cent questions supplémentaires, tirées avec une graine fixe indépendante de la graine d'entraînement, sont réservées pour la validation, de façon identique quelle que soit la variante testée. Ce jeu de validation fixe est ce qui rend comparables entre elles les différentes ablations de rang, de cibles et de taille d'entraînement présentées en section 5.6, plutôt que de ne suivre que la perte d'entraînement, qui ne dit rien sur la capacité du modèle à généraliser à des questions jamais vues.

4.5 Protocole statistique

Contrairement à une comparaison sur un petit échantillon avec un seul chiffre par configuration, chaque configuration est évaluée sur l'ensemble des 222 questions de test, et chaque score moyen est accompagné d'un intervalle de confiance à 95 % obtenu par rééchantillonnage bootstrap. Concrètement, cette technique consiste à tirer au hasard, avec remise, 222 questions parmi les 222 disponibles, certaines se retrouvant donc plusieurs fois dans un même tirage et d'autres aucune, à recalculer le score moyen sur ce tirage, et à répéter l'opération 1000 fois. Les bornes de l'intervalle sont ensuite lues directement dans cette distribution simulée de 1000 scores, en écartant les 2,5 % de valeurs les plus basses et les 2,5 % de valeurs les plus hautes, ce qui donne une fourchette de valeurs plausibles plutôt qu'une seule valeur considérée comme exacte.

Pour chaque paire de configurations, deux tests de significativité sont appliqués en parallèle. Le test bootstrap apparié reprend le même principe de rééchantillonnage, mais appliqué cette fois aux différences de score question par question entre les deux configurations comparées. Il compte, sur les 1000 tirages, dans quelle proportion cette différence moyenne change de signe par rapport à la différence observée sur les vraies données, et cette proportion sert d'estimation de p-valeur, sans supposer une forme particulière pour la distribution des différences. Le test de Wilcoxon signé procède autrement, il classe les différences par valeur absolue croissante, additionne séparément les rangs des différences positives et négatives, puis compare la plus petite des deux sommes à sa distribution théorique sous l'hypothèse d'absence de différence. Quand les deux tests s'accordent, la conclusion est traitée comme solide. Quand ils divergent, la comparaison est traitée comme non tranchée plutôt que résolue en faveur du test le plus favorable. Une correction

de Holm-Bonferroni est appliquée pour tenir compte du fait de tester six paires à la fois, un problème dit de comparaisons multiples, où tester plusieurs hypothèses en parallèle augmente mécaniquement le risque de trouver un résultat significatif par pur hasard si aucune correction n'est appliquée. Concrètement, les six p-valeurs sont ordonnées de la plus petite à la plus grande, et la i-ième plus petite est comparée à $\alpha/(6-i+1)$ plutôt qu'à un seuil fixe, un seuil de plus en plus permissif à mesure qu'on avance dans le classement, ce qui contrôle le risque global de fausse découverte sur l'ensemble des six tests plutôt que sur chacun séparément.

Pour l'évaluation humaine (section 5.7), l'accord entre deux annotateurs est mesuré par le Kappa de Cohen

$$\kappa = \frac{p_o - p_e}{1 - p_e},$$

avec p_o la proportion observée d'accord, c'est-à-dire la part des questions où les deux annotateurs ont donné exactement la même réponse, et p_e la proportion d'accord attendue par pur hasard, calculée à partir de la fréquence à laquelle chaque annotateur choisit chaque option indépendamment de l'autre. Le Kappa vaut 0 quand l'accord observé n'est pas meilleur que ce hasard-là, et 1 en cas d'accord parfait, ce qui évite de confondre un accord élevé avec un simple biais partagé vers une réponse majoritaire, deux annotateurs qui préfèrent tous les deux très souvent la même configuration par défaut peuvent sembler d'accord sans avoir vraiment jugé la même chose au cas par cas.

5. Résultats

5.1 Recherche documentaire, évaluation et pistes d'amélioration

Avant de nous intéresser à la génération de texte, il fallait d'abord vérifier une chose, la recherche documentaire trouve-t-elle le bon article de loi. Ce point conditionne tout le reste, aucune qualité de rédaction ne peut compenser un article manquant. Nous avons comparé quatre méthodes de recherche plu tôt qu'une seule, pour ne pas présupposer qu'un mo dèle d'embedding généraliste serait automatiquement le meilleur choix sur un vocabulaire aussi spécialisé que le vocabulaire juridique. Le tableau 2 présente ces quatre méthodes sur les 222 questions de test, mesurées par trois indicateurs complémentaires. Le Recall@1 mesure si le bon article arrive en première position du classement. Le Recall@10 mesure s'il figure quelque part parmi les dix premiers résultats. Le MRR@10 tient compte en plus de sa position exacte, un article trouvé en deuxième po sition compte davantage qu'un article trouvé en dixième position

Table 2. Comparaison des méthodes de recherche sur les 222 questions test.

Méthode	R@1	R@10	MRR@10
mpnet (initial)	0,021	0,097	0,105
BM25	0,063	0,224	0,215
e5-large	0,083	0,296	0,288
Hybride (BM25+e5)	0,106	0,322	0,312

Passer d'un modèle d'embedding généraliste (mpnet) à un modèle multilingue plus large (e5-large) améliore nettement le Recall@1. Plus surprenant, BM25, une mé thode purement lexicale qui se contente de compter les mots communs entre la question et l'article sans aucun apprentissage, obtient un meilleur score que le modèle d'embedding généraliste initial. Ce résultat suggère que le vocabulaire juridique est mal couvert par des embed dings entraînés sur du texte généraliste. Combiner les deux méthodes améliore encore chaque score. Mais même avec cette combinaison, le bon article manque encore dans plus de deux cas sur trois parmi les dix premiers résultats. Ce plafond nous a poussés à tester trois pistes d'amé lioration plutôt que de conclure trop vite à une difficulté intrinsèque du corpus. Chacune de ces pistes cible une explication différente du même problème, résumées dans le tableau 3

Table 3. Ablation retrieval, toutes variantes sur e5-large.

Variante	R@1	R@10	MRR@10
Base	0,083	0,296	0,288
+ Métadonnées	0,119	0,363	0,334
Découpage 256	0,083	0,330	0,306
+ Reranker	0,151	0,353	0,396

La première piste enrichit chaque fragment indexé avec ses métadonnées hiérarchiques, le code, le chapitre et la section auxquels il appartient. Elle fait remonter le Recall@1 de 0,083 à 0,119, ce qui confirme qu'une partie de la difficulté initiale venait d'un manque d'indices textuels plutôt que d'une limite dure du corpus. La deuxième piste découpe les articles en fragments de 256 tokens, ce qui donne 27 540 fragments contre 22 633 articles au départ. Elle n'apporte en revanche aucun gain net sur Recall@1. Ce résultat est cohérent avec la longueur des articles de BSARD, dont la moitié font moins de 77 mots, la grande majorité n'a donc simplement pas besoin d'être découpée. La troisième piste, un rerankeur cross-encodeur, reste la plus efficace, avec un Recall@1 de 0,151, près du double de la base. Elle est en plus la moins coûteuse en temps de calcul, puisqu'elle ne retravaille qu'un petit nombre de candidats déjà retrouvés au lieu de fouiller le corpus entier (figure 2). Ce dernier point en fait un candidat naturel à intégrer par défaut dans le pipeline plutôt qu'à garder comme simple variante testée à part.

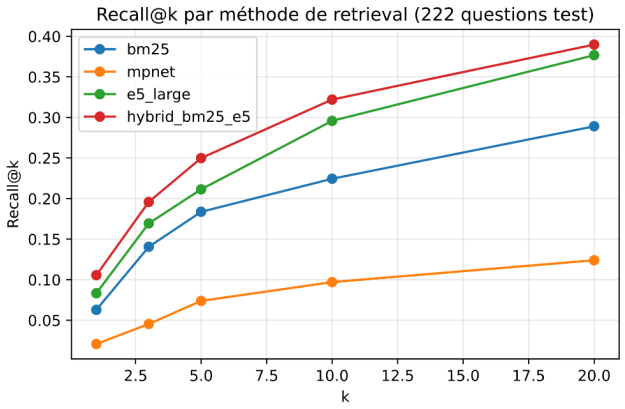


FIGURE 2. Recall@k selon la méthode de recherche, 222 questions de test.

5.2 Comparaison globale des quatre configurations

Le tableau 4 présente la comparaison principale, mesurée par le ROUGE-L, un score qui compare le texte généré au texte de référence attendu et qui vaut 0 pour aucune ressemblance et 1 pour un texte identique. Ajouter le RAG seul ou le fine-tuning seul améliore chacun nettement la qualité par rapport à l'absence d'adaptation, et combiner les deux fait encore mieux en moyenne. Chaque score moyen est accompagné d'un intervalle de confiance à 95 % (les colonnes IC bas et IC haut), obtenu par rééchantillonnage bootstrap. Cette technique consiste à repiocher au hasard, avec remise, parmi les 222 questions, à recalculer le score à chaque tirage, et à répéter l'opération 1000 fois, ce qui donne une fourchette de valeurs plausibles plutôt qu'un seul chiffre pris pour argent comptant.

TABLE 4. ROUGE-L moyen avec intervalles de confiance bootstrap à 95 %.

Config.	ROUGE-L	IC bas	IC haut
C1 zero-shot	0,110	0,104	0,116
C2 RAG	0,140	0,129	0,151
C3 fine-tune	0,147	0,136	0,160
C4 fine-tune+RAG	0,179	0,157	0,202

Les tests de significativité appariés nuancent cependant ce classement brut, un score plus haut sur 222 questions ne prouve pas à lui seul qu'une méthode est vraiment meilleure, l'écart pourrait venir du hasard du tirage de ces questions précises. Deux tests différents ont donc été appliqués à chaque paire de configurations. Le test bootstrap apparié compare directement, question par question, l'écart de score entre deux configurations. Le test de Wilcoxon signé, plus prudent, ne regarde pas la taille de cet écart mais seulement si une méthode l'emporte plus souvent que l'autre. Quand les deux tests s'accordent, la conclusion est traitée comme solide, quand ils divergent, elle est traitée comme non tranchée plutôt que résolue en faveur du résultat le plus favorable. La différence entre C2 et C3 n'est pas significative, les deux tests s'accordant là-dessus, ce qui veut dire que RAG et fine-tuning sont statistiquement indiscernables l'un de l'autre sur ROUGE-L malgré ce que suggèrent les moyennes brutes. La comparaison entre C3 et C4 est le seul cas où les deux tests ne s'accordent pas (le bootstrap la juge significative, Wilcoxon non) et reste donc traitée ici comme non tranchée.

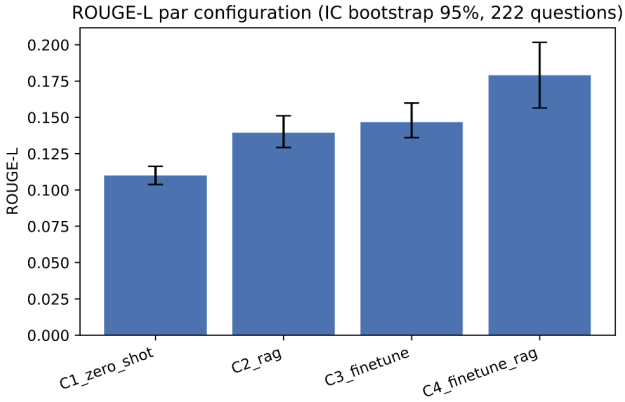


FIGURE 3. ROUGE-L avec intervalles de confiance pour les quatre configurations.

5.3 Fiabilité des citations, origine de l'erreur et abstention

Puisque la citation d'article est au cœur du sujet, le tableau 5 regarde ce chiffre séparément du recouvrement lexical global mesuré par ROUGE-L.

TABLE 5. Fiabilité des réponses, exactitude de citation et hallucination.

Config	Précision	Rappel	Exact	Halluc.
C1	0,016	0,011	0,005	0,144
C2	0,176	0,132	0,036	0,234
C3	0,023	0,012	0,000	0,050
C4	0,069	0,053	0,005	0,167

Quatre indicateurs sont utilisés. Supposons qu'une question attende trois articles gold, disons les articles 10, 15 et 22, et que le modèle ne cite que l'article 15. La précision vaut alors 1/1, soit 100 %, parce que tout ce que le modèle a dit était correct, tandis que le rappel ne vaut que 1/3, soit 33 %, parce qu'il n'a retrouvé qu'un tiers de ce qu'il fallait dire. Si le modèle avait au contraire cité les articles 10, 15, 22 et un article 99 sans rapport, la précision tomberait à 3/4 (75 %) mais le rappel monterait à 3/3 (100 %), il aurait tout retrouvé au prix d'une citation en trop. L'exactitude stricte représente les deux mesures accomplies à la fois. Le taux d'hallucination représente un article inventé.

Le RAG obtient de loin la meilleure exactitude de citation, ce qui est logique puisqu'il a accès au texte réel de l'article au moment de répondre. Le fine-tuning seul obtient en revanche le taux d'hallucination le plus bas des quatre configurations, presque trois fois moins que le RAG. Le fine-tuning apprend donc à être prudent,

il invente moins de références, mais sans pour autant citer souvent la bonne, tandis que le RAG cite plus souvent juste mais hallucine aussi plus souvent lorsqu'il se trompe.

Pour comprendre d'où vient l'erreur restante du RAG, une expérience de contexte oracle a été menée, où les vrais articles pertinents sont placés directement dans le prompt sans passer par le moteur de recherche, ce qui retire complètement l'erreur de recherche. L'écart entre recherche réelle et contexte oracle est très net sur l'exactitude de citation (0,036 contre 0,311, un écart de 0,275), nettement plus grand que l'écart entre recherche réelle et absence totale de contexte. L'essentiel de ce qui manque vient donc de la recherche documentaire qui ne trouve pas le bon article, plutôt que du modèle qui échouerait à exploiter un bon article une fois qu'il l'a.

Le taux d'hallucination est plus élevé avec la recherche réelle (0,234) qu'avec aucun contexte du tout (0,144), et redescend sous contexte oracle (0,117). Un article plausible mais faux semble inviter le modèle à une invention plus confiante qu'une absence totale d'information. Ce même schéma, le RAG améliore la qualité globale tout en augmentant le risque d'hallucination, a été retrouvé en reproduisant le protocole C1/C2 avec Qwen2.5-7B-Instruct à la place de Mistral, ce qui écarte l'hypothèse d'une simple particularité de modèle.

Enfin, aucune des mesures précédentes ne dit si le système sait reconnaître qu'il ne devrait pas répondre. Un ensemble de 50 questions hors du champ de compétence du système a été construit à cet effet, mélangeant des questions sans contenu juridique, des questions sur un droit étranger et des questions référençant un article retiré de l'index. Le résultat est sans appel, le taux d'abstention correcte reste proche de zéro pour toutes les configurations testées. Même pour une question totalement étrangère au droit, le système produit une réponse d'apparence confiante, numéros d'article inventés inclus, dans la quasi-totalité des cas. C'est la faiblesse la plus nette de ce travail, et aucune des deux techniques testées ne la corrige d'elle-même.

5.4 Deux vérifications de robustesse

Avant d'interpréter plus loin les écarts de citation, deux points de robustesse ont été vérifiés directement plutôt que supposés.

Le premier concerne le format des numéros d'articles. Environ 32 % des identifiants BSARD ne sont pas purement numériques (formats régionaux belges comme « L1122-9 » ou « R.II.21-7 »), ce qui pose la question de savoir si le modèle cite moins bien ces références irrégulières, plus difficiles à reproduire mot pour mot en générant du texte. Un test de Mann-Whitney, qui compare deux groupes de questions sans supposer une distribution particulière, a été appliqué séparément à chaque configuration entre les questions dont l'article gold a un identifiant simple et celles dont l'identifiant est structuré.

Table 6. Exactitude de citation selon le format de l'identifiant gold, test de Mann-Whitney.

Config	Simple	Structuré	Hasard
C1 zero-shot	0,85 %	0 %	35 %
C2 rag	6,78 %	2,88 %	18 %
C3 finetune	0 %	0 %	100 %
C4 finetune+rag	0,85 %	0 %	35 %

La différence va bien dans le sens attendu partout où elle est mesurable, surtout pour le RAG, mais aucune n'atteint le seuil de signification usuel de 5 %. Ce résultat montre surtout qu'il n'y a pas assez de preuves pour confirmer un effet, plutôt que de prouver qu'il n'y en a pas, l'exactitude de citation étant un événement rare, le test dispose de très peu de matière pour trancher, en particulier pour le fine-tuning seul qui n'a aucun succès dans les deux groupes.

Le second point concerne la stabilité des mesures elles-mêmes. Le modèle génère avec une température non nulle, donc deux exécutions de la même configuration sur les mêmes questions peuvent produire des réponses différentes. Le RAG a été relancé intégralement trois fois sur les 222 questions avec trois tirages aléatoires distincts. Le ROUGE-L varie de moins de 2 % relatifs d'une exécution à l'autre, mais le taux de citations exactement correctes varie de près de 31 % relatifs, ce qui représente concrètement deux à trois questions sur 222 qui basculent d'une exécution à l'autre. Comme ce taux est déjà faible en valeur absolue, cette bascule pèse lourd en proportion. C'est pour cette raison que les tests de significativité de la section 5.2 portent sur le ROUGE-L, la mesure stable, plutôt que sur l'exactitude de citation, plus informative mais plus bruitée à température non nulle.

5.5 Ce qui rend une question difficile

La performance moyenne cache des écarts entre catégories juridiques et entre questions. La figure 4 et le tableau 7 décomposent le ROUGE-L par catégorie et par configuration.

Table 7. ROUGE-L moyen par catégorie juridique et par configuration.

Catégorie	n	C1	C2	C3	C4
Famille	67	0,117	0,146	0,179	0,182
Logement	66	0,118	0,140	0,149	0,216
Argent	36	0,112	0,167	0,128	0,191
Justice	30	0,082	0,099	0,105	0,116
Étrangers	13	0,096	0,118	0,126	0,117
Travail	6	0,121	0,153	0,154	0,138
Prot. sociale	4	0,087	0,126	0,112	0,137

Le classement global des quatre configurations se maintient globalement à travers les catégories, mais avec des amplitudes très différentes. Logement montre le plus grand écart entre C1 et C4 (0,118 à 0,216), ce qui suggère

que le fine-tuning et le RAG s'y renforcent particulièrement bien, tandis que sur Travail le fine-tuning seul égale ou dépasse déjà la configuration combinée. Protection sociale, avec seulement quatre questions de test, reste peu concluante et sert davantage d'illustration que de preuve.

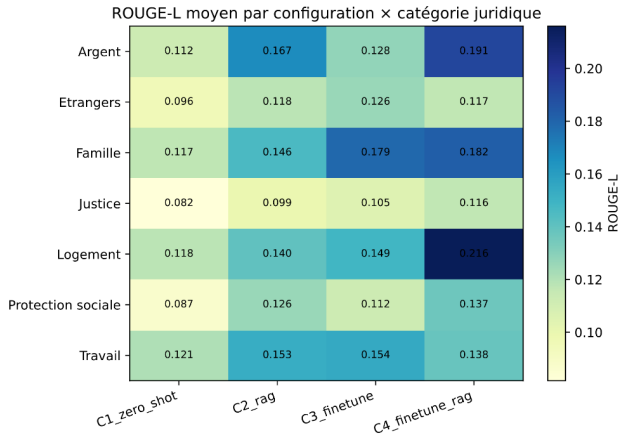


FIGURE 4. ROUGE-L moyen par configuration et catégorie juridique.

Au-delà de la catégorie, deux hypothèses ont été testées directement pour expliquer pourquoi certaines questions obtiennent de meilleures réponses que d'autres, la longueur de la question et le nombre d'articles de loi nécessaires pour y répondre, en calculant pour chacune une corrélation de Spearman avec le ROUGE-L obtenu. Cette corrélation remplace les valeurs brutes par leur rang avant de calculer le coefficient usuel, ce qui la rend sensible à une relation monotone plutôt que spécifiquement linéaire.

TABLE 8. Corrélation de Spearman entre difficulté et ROUGE-L.

Config	ρ longueur	ρ nb. articles
C1	$-0,107$	$-0,491$
C2	$-0,076$	$-0,394$
C3	$-0,064$	$-0,510$
C4	$-0,152$	$-0,353$

La longueur de la question n'a quasiment aucun lien avec la qualité de la réponse. Le nombre d'articles nécessaires, en revanche, corrèle négativement et de façon hautement significative avec la qualité dans les quatre configurations sans exception ($p < 0,0001$ partout), ce qui veut dire que la longueur était le mauvais indicateur de difficulté depuis le début, le vrai facteur étant le nombre de règles distinctes à combiner dans une même réponse. La qualité chute nettement dès que quatre articles ou plus sont nécessaires, dans chaque configuration, et ni le RAG ni le fine-tuning ne corrigent ce problème structurel d'eux-mêmes.

Cette observation a motivé une dernière question. Peut-on prédire, à partir de caractéristiques observables avant même la génération (longueur de la question, nombre d'articles gold, catégorie, régularité du format d'identifiant, configuration), si une réponse va être peu fiable ? Un classifieur de régression logistique et une Forêt Aléatoire, entraînés sur les 888 observations disponibles avec validation croisée à 5 plis, font nettement mieux qu'un classifieur naïf (AUC de 0,878 et 0,838 contre 0,50 pour la classe majoritaire, figure 5), à nuancer toutefois par le déséquilibre marqué de la cible, seulement 1,1 % des réponses obtiennent une citation exactement correcte, ce qui donne à cette classe positive très peu d'exemples sur lesquels s'appuyer.

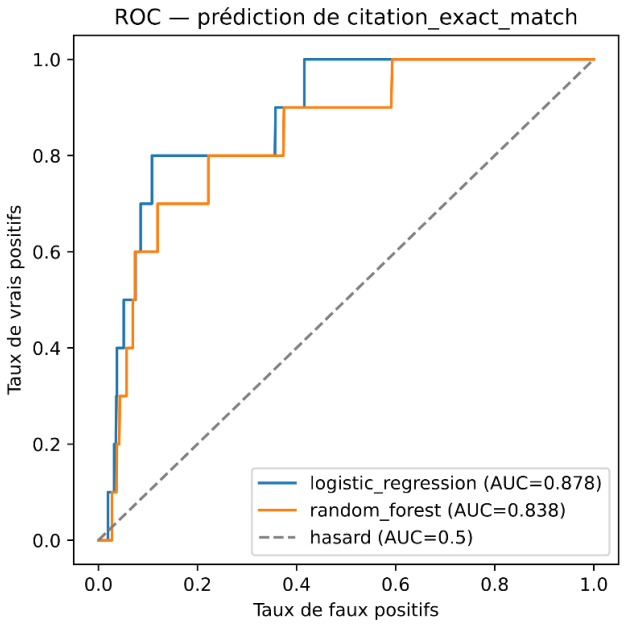


FIGURE 5. Courbe ROC des deux classifieurs de fiabilité de citation.

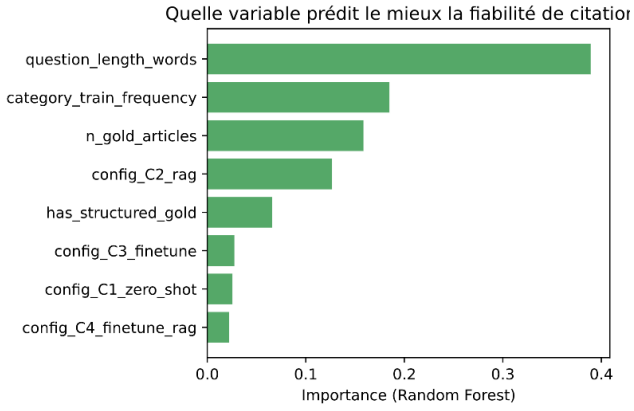


FIGURE 6. Importance des variables pour prédire l'exactitude de citation.

L'importance des variables montre que la longueur de la question est le facteur le plus important. Suivie de la fréquence de la catégorie dans le train et le nombre d'articles gold. À l'inverse, la configuration utilisée a une influence assez faible. Cela signifie que les caractéristiques de la question ont davantage d'impact sur

la fiabilité de la réponse que le choix entre RAG et fine-tuning. Ce résultat rejoint donc l'observation faite précédemment sur le nombre d'articles nécessaires.

En revanche, ces mêmes variables expliquent seulement environ 13 % des variations du score ROUGE-L, alors qu'elles permettent de prédire beaucoup mieux l'exactitude de la citation. Cela montre que retrouver le bon article et produire une réponse proche de celle attendue sont deux choses qui ne dépendent pas exactement des mêmes facteurs. Il est donc préférable de conserver ces deux types de mesures séparés plutôt que de les regrouper dans un seul score.

5.6 Ablations du fine-tuning

Pour éviter de tirer une conclusion d'une seule expérience de fine-tuning, sept variantes supplémentaires ont été testées en changeant un seul facteur à la fois par rapport à la configuration principale (tableau 9).

TABLE 9. Variantes de fine-tuning.

Variante	n	Loss train	Loss val.
Principale (r=32)	580	0,834	0,679
Rang r=8	580	0,850	0,710
n=190	190	1,122	1,098
n=380	380	0,966	0,860
n=786	786	0,736	0,561
Attn + MLP	580	0,527	0,416
+ Synthétique	2580	0,940	0,516

Augmenter la taille du jeu d'entraînement améliore régulièrement la perte de validation sans signe de saturation (figure 7), le point à 786 exemples, le maximum disponible dans BSARD, n'ayant pas encore atteint de plateau. Passer d'un rang 8 à un rang 32 (à nombre d'exemples égal) améliore la perte de validation de 0,710 à 0,679, un gain réel mais modeste pour quatre fois plus de paramètres entraînés. Étendre l'adaptateur aux couches de réseau direct en plus de l'attention (colonne Attn + MLP) fait nettement baisser cette perte, le plus gros gain absolu, mais au prix d'un écart plus marqué entre perte d'entraînement et perte de validation, signe d'un sur-apprentissage plus fort. Ajouter 2000 exemples générés automatiquement au jeu d'entraînement officiel donne la meilleure perte de validation de toute la campagne, un résultat encourageant mais qui mériterait d'être confirmé par une relecture qualitative de ces exemples synthétiques avant d'être pleinement adopté.

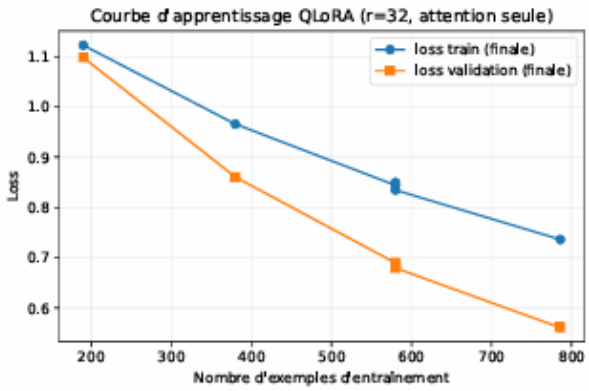


FIGURE 7. Perte de validation selon la taille du jeu d'entraînement.

La configuration principale a aussi été répétée sur trois graines aléatoires, car une seule exécution ne suffit pas pour tirer une conclusion solide. La perte d'entraînement finale est stable d'une graine à l'autre, mais la qualité des réponses réellement générées varie davantage. Pour la configuration combinée, le ROUGE-L moyen sur les trois graines est plus bas que celui rapporté dans le tableau 4, qui correspond en fait à la graine la plus favorable des trois plutôt qu'à une moyenne représentative. Sur ROUGE-L, la configuration combinée ne bat le fine-tuning seul que sur deux des trois graines, ce qui montre que sa supériorité, bien que réelle en moyenne, n'est pas systématique et doit être nuancée plutôt que présentée comme acquise dans l'absolu.

Une dernière expérience a testé si un adaptateur entraîné sur un seul domaine juridique fait mieux sur ce domaine qu'un adaptateur généraliste entraîné sur tout. Un adaptateur spécialiste, entraîné uniquement sur les 331 questions d'entraînement touchant au Code Civil (contre 580 pour le généraliste), atteint une perte d'entraînement proche de celle de la configuration principale, mais sa perte de validation explose, le plus grand écart de sur-apprentissage de toute la campagne. Sur son propre domaine, ce spécialiste est légèrement meilleur en ROUGE-L que le généraliste mais hallucine nettement plus. Une limite doit être posée clairement ici. Le jeu de validation utilisé pour mesurer cette perte contient des questions de tous les domaines, pas seulement du Code Civil, ce qui désavantage mécaniquement le spécialiste, évalué sur des questions bien plus larges que celles sur lesquelles il a appris. Le spécialiste dispose en plus de moins d'exemples d'entraînement que le généraliste, 331 contre 580. Cette expérience mélange donc deux effets différents, celui de la restriction à un seul domaine et celui de la quantité de données disponible, et ne permet donc pas à elle seule de savoir si se spécialiser par domaine aide vraiment. Pour séparer proprement ces deux effets, il faudrait un jeu de validation lui-même restreint au Code Civil, ce qui reste à faire.

5.7 Évaluation humaine et jugement automatique complémentaire

Toute mesure présentée jusqu'ici est automatique. Pour vérifier qu'elle reflète un jugement humain réel, trois annotateurs ont comparé à l'aveugle les réponses du RAG et du fine-tuning seul sur 60 questions communes chacun, sans savoir quelle réponse venait de quelle configuration.

Table 10. Accord inter-annotateurs, Kappa de Cohen par paire.

Paire	Kappa	Accord exact	n
Bartosz vs Chaabane	0,389	56,7 %	60
Bartosz vs Arman	0,471	66,7 %	60
Chaabane vs Arman	0,331	53,3 %	60

L'accord inter-annotateurs, mesuré par le Kappa de Cohen (formulé en section 4.5), est modéré sur les trois paires entre 0,33 et 0,47.

Table 11. Distribution de l'accord sur les 60 questions communes.

Niveau d'accord	Part des questions
Unanime (3 voix sur 3)	45,0 %
Majoritaire (2 voix sur 3)	41,7 %
Aucun accord	13,3 %

Le tableau 11 montre que les trois annotateurs sont unanimes dans 45 % des cas et qu'un accord au moins majoritaire est atteint plus de huit fois sur dix, ce qui reste raisonnable pour une tâche de préférence subjective.

Table 12. Préférence par catégorie juridique en % des votes, trois annotateurs combinés.

Catégorie	n	RAG	FT	Égal.	Aucun
Famille	30	86,7	6,7	0,0	6,7
Argent	30	76,7	3,3	10,0	10,0
Justice	30	70,0	3,3	16,7	10,0
Travail	18	72,2	0,0	11,1	16,7
Logement	30	66,7	6,7	6,7	20,0
Étrangers	30	60,0	20,0	16,7	3,3
Protection sociale	12	50,0	8,3	8,3	33,3

Le tableau 12 confirme que le RAG l'emporte dans les sept catégories juridiques sans exception, de 86,7 % de préférence en Famille à 50 % en Protection sociale, la catégorie la plus étroite avec seulement 12 votes.

Table 13. Classement Bradley-Terry, sur une échelle de type Elo.

Configuration	Score
RAG (C2)	1368,7
Fine-tuning seul (C3)	631,3

Un classement par modèle de Bradley-Terry, calculé sur les 161 votes exploitables parmi les 180 recueillis (hors choix « aucun des deux »), confirme nettement cette préférence (tableau 13). Ce résultat entre en tension directe avec la comparaison automatique de la section 5.2, qui ne trouvait pas de différence significative entre RAG et fine-tuning sur ROUGE-L. Plutôt qu'une contradiction à résoudre, cet écart illustre concrètement pourquoi une métrique de surface et un jugement humain à l'aveugle ne vont pas toujours dans le même sens, et justifie de les mesurer côte à côte plutôt que de se fier à un seul type de signal.

En complément, une métrique de fidélité déterministe mesure le recouvrement des entités nommées et des nombres extraits du texte généré avec ceux du texte de référence

$$\text{fidélité} = \frac{|PI_{réponse} \cap PI_{fragment}|}{|PI_{réponse}|},$$

avec PI l'ensemble des éléments d'intérêt (entités, nombres) extraits d'un texte. Un jugement de pertinence par un LLM indépendant, Phi-3.5-mini-instruct, choisi précisément parce qu'il n'est ni l'un des systèmes comparés ni le second modèle de base testé, complète cette mesure, chaque réponse étant notée dix fois à température non nulle et les scores moyennés pour éviter de se fier à un jugement unique instable, sur une échelle de 1 à 5.

Table 14. Fidélité au texte de référence et pertinence jugée par LLM.

Configuration	Fidélité	Pertinence /5
C1 zero-shot	0,054	5,00
C2 RAG	0,295	4,85
C3 fine-tune	0,298	4,73
C4 fine-tune + RAG	0,324	4,62

Le tableau 14 montre un contraste attendu sur la fidélité, très basse pour C1 en l'absence de tout contexte ou adaptation (0,054), et nettement plus haute dès qu'un contexte ou un entraînement intervient, jusqu'à 0,324 pour la combinaison C4. La pertinence jugée suit en revanche une tendance inverse et plus surprenante, elle est maximale pour C1 (5,00) et diminue régulièrement jusqu'à C4 (4,62). Le prompt du juge demande explicitement de ne pas évaluer l'exactitude factuelle, seulement si la réponse traite bien ce qui est demandé, ce qui explique mécaniquement ce contraste. Un modèle zero-shot répond directement et de façon fluide à la question posée, sans contexte externe susceptible de le détourner du sujet, même quand il invente les détails précis. Le RAG, au contraire, peut parfois recevoir un passage mal ciblé par la recherche documentaire, comme l'exemple du règlement sur le statut de sportif de haut niveau au lieu d'un texte sur la naturalisation décrit en section 5.8, et le modèle construit alors sa réponse à partir de ce mauvais contexte plutôt que de rester centré sur la question. Le contexte récupéré, qui améliore l'ancrage factuel en moyenne, peut donc occasionnellement nuire à la per-

tinence perçue, un effet réel mais nettement plus petit que l'écart d'ancrage des citations décrit en section 5.3.

Le tableau 14 invite aussi à formuler une hypothèse supplémentaire sur l'origine de la préférence humaine très marquée pour le RAG observée plus haut. Les scores de C2 et C3 sont ici quasiment identiques, 0,295 contre 0,298 en fidélité et 4,85 contre 4,73 en pertinence, ce qui ne suffit pas à expliquer un écart humain aussi net, 1368,7 contre 631,3 sur l'échelle Bradley-Terry. Une explication plausible est qu'un annotateur humain juge aussi, au moins en partie, la forme du texte plutôt que son seul contenu factuel, une réponse mieux structurée et plus claire dans sa progression pouvant être préférée même quand son ancrage réel n'est pas meilleur. Aucune des mesures mobilisées ici, ROUGE-L, fidélité ou pertinence jugée, ne capture explicitement la structure ou la lisibilité du texte produit. La longueur moyenne des réponses, un indice brut de forme, ne soutient pas une explication aussi simple à elle seule, C3 produit en moyenne les réponses les plus longues des quatre configurations et perd pourtant nettement face à C2, plus courte, dans l'arène humaine, ce qui écarte au moins la longueur seule comme facteur explicatif. Cette hypothèse de forme reste à tester directement, par exemple en demandant aux annotateurs de noter séparément le fond et la forme, une distinction que le protocole actuel ne fait pas.

5.8 Analyse qualitative des erreurs

Au-delà des chiffres, la lecture directe des réponses annotées fait ressortir des schémas d'erreur récurrents qui donnent corps aux statistiques ci-dessus. Le plus fréquent est une inversion de rôle juridique, une obligation attribuée à la mauvaise partie, souvent sur des paires de questions qui ne diffèrent que d'un mot (par exemple « marié » contre « cohabitant légal »), où le bon article diffère d'une façon subtile facile à manquer aussi bien pour la recherche que pour la génération. Le texte de loi inventé apparaît aussi souvent. Comme l'hallucination ne disparaît pas complètement même sous contexte oracle (section 5.3), une partie au moins de ce phénomène semble être une tendance générale du modèle de base plutôt qu'une simple conséquence d'une mauvaise recherche. Un nombre plus restreint de réponses dérivent entièrement de la question posée, généralement lorsqu'un passage retrouvé est proche du sujet sans vraiment y répondre, ce qui explique la légère dégradation de pertinence jugée observée en section 5.7. Enfin, un dernier schéma de texte répété ou coupé ressemble davantage à un problème de réglage du décodage qu'à une limite du modèle lui-même, puisque la génération n'utilise actuellement aucune pénalité de répétition explicite.

Deux exemples concrets illustrent ces schémas, le premier chiffré sur l'ensemble du test plutôt que sur un cas isolé. L'article 1475 du Code Civil, sur la cohabitation légale, apparaît dans 31 réponses sur 222 pour le fine-tuning seul, soit 14,0 %, contre seulement 2 pour le RAG, 2 pour la combinaison RAG et fine-tuning, et aucune pour le zero-shot. Parmi ces 31 réponses, seules deux correspondent effectivement à une question dont l'article gold est le 1475, les 29 autres, soit 13,1 % de tout le test pour cette configuration, citent cet article alors qu'il ne correspond pas à la question posée. Le modèle semble avoir mémorisé un exemple d'entraînement sur ce thème et le ressortir presque tel quel dès qu'il reconnaît un vocabulaire proche, sans vraiment traiter la question posée. Une bonne partie de ces citations ne sont pas comptées comme des hallucinations par notre métrique automatique puisque l'article cité existe réellement, ce qui montre qu'une citation fausse mais plausible échappe largement à cette mesure. Ce comportement est propre au fine-tuning seul, il retombe au niveau du RAG dès que celui-ci est ajouté, ce qui suggère que le contexte récupéré aide aussi à sortir le modèle de ce schéma mémorisé plutôt que de seulement fournir de l'information supplémentaire.

Sur une question de naturalisation belge, Mistral en zero-shot invente quant à lui une administration, l'Office fédéral de l'immigration et de l'intégration, qui n'existe pas en Belgique sous ce nom, l'organisme compétent étant l'Office des étrangers. L'acronyme correspondant désigne en réalité une administration française, un exemple concret de confusion entre systèmes administratifs nationaux. Sur cette même question de naturalisation, le RAG ne se trompe pas de la même façon, le moteur de recherche retrouve des passages complètement hors sujet, notamment un règlement sur le statut de sportif de haut niveau, et le modèle construit alors sa réponse à partir de ce mauvais contexte sans jamais parler de naturalisation. Comme la génération dépend directement de ce que la recherche a fourni, une erreur au moment de la recherche se répercute mécaniquement sur la réponse finale, un enchaînement qui contribue à expliquer pourquoi le RAG obtient des scores particulièrement bas sur la catégorie Étrangers, seulement 13 questions de test, où quelques erreurs de recherche comme celle-ci suffisent à faire chuter la moyenne de toute la catégorie.

5.9 Réponses aux questions de recherche et positionnement

Sur la première question, un modèle spécialisé par fine-tuning peut-il rivaliser avec un modèle généraliste appuyé sur le RAG, la réponse est globalement oui sur les métriques automatiques, C3 n'étant pas statistiquement distinguable de C2 sur ROUGE-L, mais nettement non du point de vue humain, où le RAG est très majoritairement préféré. C'est précisément le type d'écart que ce travail cherchait à mettre en évidence en mesurant les deux types de signal côte à côte.

Sur la deuxième question, le fine-tuning seul améliore nettement le taux d'hallucination par rapport à toutes les autres configurations, ce qui est un gain réel et spécifique. Combiné au RAG, il améliore encore le ROUGE-L moyen, mais cette supériorité n'est confirmée ni par les tests de significativité ni de façon systématique à travers les trois graines testées, le gain existe en moyenne mais n'est pas garanti sur une seule exécution.

Sur la troisième question, la réponse est clairement

négative sur le second point. Le taux d'abstention correcte sur des questions hors champ reste proche de zéro pour toutes les configurations testées, et c'est là le problème le plus sérieux de ce travail, plus que le choix entre RAG et fine-tuning.

Comme dans l'étude de référence présentée en section 3.3, nous trouvons que le RAG est nettement préféré par les annotateurs humains au fine-tuning seul, avec une ampleur d'écart comparable. Là où nos résultats divergent, c'est sur les métriques automatiques, cette étude trouvait le RAG systématiquement meilleur que le fine-tuning sur la pertinence et la fidélité jugées, tandis que nous ne trouvons pas de différence significative entre RAG et fine-tuning sur ROUGE-L, et trouvons même le fine-tuning nettement meilleur sur le taux d'hallucination. L'explication la plus probable, déjà discutée en section 3.3, est méthodologique, notre fine-tuning est supervisé sur des paires question-réponse là où l'autre était une poursuite non supervisée du pré-entraînement.

6. Conclusion et perspectives

Plusieurs limites doivent être gardées en tête en lisant ces résultats. BSARD porte sur le droit belge francophone et non français. L'absence de réponse gold rédigée oblige à reconstruire une référence par concaténation d'articles, ce qui pèse sur l'interprétation des scores de similarité de surface (section 4.1). Seules deux familles de modèles de base, Mistral et Qwen, ont été testées, ce qui laisse ouverte la question de savoir si les schémas observés se généraliseraient à des modèles beaucoup plus grands ou entraînés différemment. Et l'accord inter-annotateurs de l'arène humaine, bien que rapporté honnêtement, reste modéré plutôt que fort.

Ce travail compare le RAG et le fine-tuning QLoRA sur un assistant de question-réponse juridique en français, avec un protocole étendu par rapport à une comparaison sur petit échantillon, jeu de test complet, intervalles de confiance, tests appariés, une dizaine d'ablations complémentaires, décomposition de l'erreur retrieval et génération, et évaluation humaine à trois annotateurs. Le RAG et le fine-tuning apportent chacun un gain net et distinct par rapport à l'absence d'adaptation, le RAG améliore surtout l'exactitude de citation, le fine-tuning améliore surtout la prudence face à l'invention. Les combiner améliore encore le résultat en moyenne, sans que ce gain soit systématique d'une exécution à l'autre. Le problème le plus sérieux mis en évidence n'est pas un manque de qualité sur les bonnes questions, mais l'incapacité quasi totale du système à reconnaître les mauvaises.

Pris ensemble, ces résultats suggèrent une recommandation pratique plutôt qu'un modele parfait. Si l'objectif est la traçabilité stricte des sources, le RAG le plus fiable et la plus facile à maintenir à jour. Si l'objectif est d'éviter l'invention pure, le fine-tuning supervisé apporte un gain spécifique que le RAG seul n'apporte pas. Combiner les deux améliore le résultat moyen mais ajoute de la variance et double le coût de maintenance, ce qui n'en fait pas un choix par défaut évident dans tous les contextes de déploiement.

Plusieurs pistes restent ouvertes pour un travail futur. Un stress-test adversarial construit spécifiquement autour de références d'articles plausibles mais inexistantes permettrait de mieux cerner la capacité d'abstention. Pour les catégories les plus rares comme Protection sociale, où le nombre de questions est trop petit pour trancher avec confiance, un calcul de puissance statistique permettrait de savoir si l'absence de résultat significatif reflète une vraie absence d'effet ou simplement un échantillon insuffisant. Améliorer encore la recherche documentaire elle-même reste aussi une piste centrale, puisque c'est elle qui borne tout le reste, même la meilleure variante testée en section 5.1 ne place le bon article en première position que dans 15,1 % des cas, et aucune qualité de rédaction en aval ne peut compenser un article manquant dès le départ. Mais la piste la plus prometteuse reste, de loin, un travail ciblé sur la capacité d'abstention, puisque c'est la faiblesse la plus sérieuse mise en évidence par ce travail.

Références

[1] A. Balaguer et al. RAG vs fine-tuning. arXiv :2401.08406, 2024.

[2] C. Bouvard, M. Ciancone, A. Gourru, M. Schaeffer. Derby LLM. APIA@PFIA 2024, HAL hal-04638460.

[3] I. Chalkidis et al. LexGLUE. ACL 2022, arXiv :2110.00976.

[4] J. Chen, S. Xiao, P. Zhang, K. Luo, D. Lian, Z. Liu. M3-embedding. arXiv :2402.03216, 2024.

[5] W.-L. Chiang et al. Chatbot arena. arXiv :2403.04132, 2024.

[6] T. Dettmers, A. Pagnoni, A. Holtzman, L. Zettlemoyer. QLoRA. arXiv :2305.14314, 2023.

[7] S. Es, J. James, L. Espinosa-Anke, S. Schockaert. Ragas. arXiv :2309.15217, 2023.

[8] N. Guha et al. LegalBench. arXiv :2308.11462, 2023.

[9] D. Hendrycks, C. Burns, A. Chen, S. Ball. CUAD. NeurIPS 2021, arXiv :2103.06268.

[10] E. J. Hu et al. LoRA. arXiv :2106.09685, 2021.

[11] A. Q. Jiang et al. Mistral 7b. arXiv :2310.06825, 2023.

[12] V. Karpukhin et al. Dense passage retrieval. EMNLP 2020, arXiv :2004.04906.

[13] P. Lewis et al. Retrieval-augmented generation for knowledge-intensive NLP tasks. NeurIPS 2020, arXiv :2005.11401.

[14] C.-Y. Lin. ROUGE. Text Summarization Branches Out, 2004.

[15] A. Louis, G. Spanakis. A statutory article retrieval dataset in French. ACL 2022, arXiv :2108.11792.

[16] A. Louis, G. van Dijck, G. Spanakis. Interpretable long-form legal question answering. arXiv :2309.17050, 2023.

[17] L. Ouyang et al. Training language models to follow instructions with human feedback. arXiv :2203.02155, 2022.

[18] O. Ovadia, M. Brief, M. Mishaeli, O. Elisha. Fine-tuning or retrieval. arXiv :2312.05934, 2023.

[19] A. Vaswani et al. Attention is all you need. NeurIPS 2017, arXiv :1706.03762.

[20] T. Zhang, V. Kishore, F. Wu, K. Q. Weinberger, Y. Artzi. BERTScore. ICLR 2020, arXiv :1904.09675.

Annexe A. Difficultés techniques rencontrées

Cette annexe reprend, sous forme condensée, les principales difficultés techniques rencontrées au fil du projet.

— **Type de la colonne des identifiants d'article.** Ce champ de BSARD est une chaîne de caractères et non une liste. Un parsing manquant fait chuter silencieusement le Recall@k près de zéro sans erreur explicite.

— **Hétérogénéité des identifiants d'article.** Environ 32 % des identifiants d'article BSARD ne sont pas purement numériques (formats régionaux belges hétérogènes), et environ 2,5 % portent un suffixe d'annotation parasite collé par le scraping de la source. Les deux problèmes faussaient silencieusement les métriques de citation avant correction par expression régulière généralisée.

— **Absence de sauvegarde incrémentale.** Plusieurs jobs d'ablation longs ont perdu des résultats déjà calculés à cause d'un dépassement de mémoire GPU survenu avant la sauvegarde finale. Solution généralisée, sauvegarder après chaque étape indépendante plutôt que seulement à la fin du job.

— **Quota de sessions GPU Kaggle.** La limite de deux sessions GPU simultanées sur le compte gratuit a été dépassée à plusieurs reprises sans message d'erreur explicite, notamment parce qu'une nouvelle version poussée d'un kernel ne stoppe pas automatiquement la session précédente encore en cours.

— **Doublons dans les votes d'arène humaine.** Le fichier de votes d'un des trois annotateurs contenait des questions votées deux fois, probablement à la suite d'un rechargement de page en cours de session. Corrigé par déduplication systématique par identifiant de question avant tout calcul d'accord inter-annotateurs.

Annexe B. Détails d'implémentation

Configuration QLoRA complète. Rang $r = 32$, $\alpha = 32$, dropout 0,05, cibles `q_proj`, `k_proj`, `v_proj`, `o_proj`, quantification NF4 4 bits, trois époques, taille de batch 4 avec accumulation de gradient 4, taux d'apprentissage 2×10^{-4}, modèle de base `Mistral-7B-Instruct-v0.3`.

Modèle d'embedding et reranker. *multilingual-e5-large* pour la recherche dense, *bge-reranker-v2-m3* pour le reranking cross-encodeur, BM25Okapi pour la recherche lexicale, fusion par rang réciproque ($k = 60$) pour l'hybride.

Juge LLM. `Phi-3.5-mini-instruct`, choisi car absent des quatre configurations comparées et du second modèle de base testé, interrogé dix fois par réponse à température non nulle, scores moyennés.