

Université Jean Monnet Saint-Étienne

TER – Année 2025/2026

Assistant juridique fondé sur l'IA : RAG contre fine-tuning, une comparaison expérimentale

Rapport final de TER



Auteur

Bartosz Konior

M1 DSC

Co-auteur : Chaabane Ouammou

M1 MLDM

Encadrant : François Jacquenet

Co-encadrant du binôme : Amaury Habrard

Laboratoire : Laboratoire Hubert Curien, UMR CNRS 5516

Résumé

Ce rapport présente un travail de comparaison entre deux façons d'adapter un grand modèle de langage à un domaine spécialisé : la génération augmentée de récupération (RAG) et le fine-tuning paramétriquement efficace (QLoRA). Le domaine choisi est le droit, un terrain exigeant où une réponse fautive ou une citation inventée a un coût réel. Nous construisons un assistant de question-réponse juridique en français, évalué sur BSARD, un corpus de droit belge francophone, avec le modèle Mistral-7B-Instruct. Quatre configurations sont comparées sur 222 questions de test : sans adaptation, avec RAG seul, avec fine-tuning seul, et avec les deux combinés. Nous mesurons la qualité des réponses par des métriques automatiques (ROUGE-L, BERTScore, exactitude de citation, taux d'hallucination), par un jugement automatique complémentaire (LLM-juge, fidélité), et par une évaluation humaine à l'aveugle. Nos résultats montrent que le RAG et le fine-tuning apportent chacun un gain net par rapport à l'absence d'adaptation, que les combiner fait encore mieux, mais qu'aucune des deux techniques ne résout à elle seule le problème le plus sérieux constaté : le système invente des références juridiques avec assurance plutôt que de reconnaître ses limites. Ce travail se positionne explicitement par rapport à l'étude Derby LLM de Bouvard et al. [3], en étendant son protocole à un jeu de test complet, à des tests statistiques appariés, à une décomposition de l'erreur entre recherche et génération, et à une dizaine d'ablations complémentaires.

1. Introduction

Les grands modèles de langage (LLM) savent aujourd'hui rédiger un texte fluide sur à peu près n'importe quel sujet, mais leurs connaissances restent celles de leurs données d'entraînement : généralistes, souvent en anglais, et figées à une date donnée. Dès qu'on veut les utiliser sur un domaine précis et exigeant, la question se pose de savoir comment leur donner accès à des connaissances qu'ils ne possèdent pas nativement. Deux familles de réponses techniques dominent aujourd'hui la littérature et la pratique : le fine-tuning, qui réentraîne (partiellement) le modèle sur des données du domaine, et la génération augmentée de récupération (RAG), qui laisse le modèle intact mais lui fournit au moment de répondre des extraits de documents pertinents récupérés dans

une base externe.

Ce travail compare expérimentalement ces deux approches sur un cas d'usage concret : un assistant capable de répondre à des questions de droit en français, en citant l'article de loi sur lequel il s'appuie. Trois questions de recherche guident l'ensemble du travail.

1. Un modèle spécialisé par fine-tuning, même entraîné sur peu d'exemples, peut-il rivaliser avec un modèle généraliste appuyé sur une recherche documentaire externe ?
2. Dans quels cas le fine-tuning apporte-t-il un gain réel par rapport au RAG seul, et ce gain se maintient-il une fois combiné avec le RAG ?
3. Le système sait-il citer sa source de façon fiable, et reconnaît-il ses propres limites lorsqu'il ne peut pas répondre correctement ?

Ce rapport est organisé comme suit. La section 2 présente le contexte du projet. La section 3 justifie le choix du domaine juridique. La section 4 passe en revue l'état de l'art sur le fine-tuning efficient, le RAG, les comparaisons existantes entre les deux, et les méthodes d'évaluation des systèmes génératifs. La section 5 décrit les données utilisées. La section 7 présente notre contribution méthodologique : le protocole expérimental à quatre configurations et l'appareil statistique associé. La section 8 présente l'ensemble des résultats. La section 9 discute les erreurs observées qualitativement. La section 10 répond aux questions de recherche et se positionne par rapport à Derby LLM. La section 11 conclut et propose des pistes.

2. Contexte du projet

Ce travail est un TER (travail d'étude et de recherche) mené en binôme à l'université Jean Monnet de Saint-Étienne, rattaché au Laboratoire Hubert Curien (UMR CNRS 5516). L'auteur de ce rapport est inscrit en M1 Data Science (DSC), encadré par François Jacquenet ; le binôme, Chaabane Ouammou, est inscrit en M1 Machine Learning and Data Mining (MLDM), encadré par Amaury Habrard. Le code, les expériences et les données sont partagés entre les deux étudiants, mais chacun rédige son propre rapport, adapté à son parcours : celui-ci en français pour le DSC, celui de Chaabane Ouammou en anglais pour le MLDM.

Le sujet imposé demandait de comparer le RAG et le fine-tuning sur un cas d’usage concret, en se positionnant explicitement par rapport à l’étude Derby LLM [3], menée par une équipe associant l’entreprise Wikit et le Laboratoire Hubert Curien sur des données d’entreprise françaises. Une contrainte forte du projet était de n’utiliser que des ressources gratuites, sans demande d’accès à des API payantes ni à des modèles à accès restreint : tout le calcul GPU a été réalisé sur les quotas gratuits de Kaggle (GPU Tesla T4) puis sur des instances louées à l’heure sur RunPod pour les expériences les plus lourdes.

3. Pourquoi le domaine juridique ?

Le choix du domaine juridique n’est pas anodin : c’est un terrain d’expérimentation particulièrement exigeant pour un système de génération de texte, pour plusieurs raisons complémentaires.

D’abord, la précision factuelle y est cruciale. Une réponse juridique approximative n’est pas simplement moins utile qu’une réponse précise : elle peut activement induire en erreur une personne qui s’appuie dessus pour une décision réelle. Ensuite, la traçabilité de la source est une exigence du domaine lui-même, pas une contrainte que nous avons ajoutée artificiellement : une réponse juridique crédible doit s’appuyer sur un texte de loi identifiable, ce qui donne un signal de fiabilité mesurable (la référence citée existe-t-elle vraiment, et est-elle la bonne ?) là où beaucoup d’autres domaines n’offrent qu’un jugement de qualité subjectif. Le coût d’une hallucination y est également élevé et concret, contrairement à des domaines où une imprécision est plus facilement tolérée. Enfin, la structure hiérarchique du texte de loi (code, livre, titre, chapitre, article) se prête naturellement au découpage par unité citable, ce qui en fait un bon cas d’usage pour le RAG.

D’autres domaines candidats ont été écartés pour des raisons pratiques. Le domaine médical partage plusieurs de ces propriétés mais l’accès à des données réelles y est fortement restreint pour des raisons de confidentialité. Le domaine du code source, souvent utilisé comme banc d’essai pour les LLM [13], est nettement moins exigeant sur la citation précise d’une source, puisqu’un code qui fonctionne n’a pas besoin de référencer sa documentation d’origine. La disponibilité de corpus juridiques francophones librement accessibles a aussi pesé dans le choix : des jeux comme LegalBench [10], CUAD [11] ou LexGLUE [4] existent surtout en anglais, ce qui a

orienté la recherche vers des ressources francophones (section 5).

4. État de l’art

4.1 Fine-tuning efficient de grands modèles de langage

Le fine-tuning complet d’un LLM de plusieurs milliards de paramètres est coûteux en mémoire et en temps de calcul, ce qui a motivé le développement de méthodes de fine-tuning paramétriquement efficaces (*parameter-efficient fine-tuning*, PEFT). LoRA [12] propose de geler les poids du modèle pré-entraîné et d’ajouter, à côté de certaines matrices (typiquement celles de l’attention), une paire de matrices de rang faible dont le produit approxime la mise à jour qu’aurait produite un fine-tuning complet. Le nombre de paramètres entraînaibles devient ainsi une toute petite fraction du modèle total. QLoRA [7] pousse cette idée plus loin en quantifiant le modèle de base en 4 bits (format NF4) avant d’y greffer les adaptateurs LoRA, ce qui réduit fortement l’empreinte mémoire et permet d’entraîner un modèle de 7 milliards de paramètres sur un unique GPU grand public. C’est cette approche que nous utilisons (section 7).

4.2 Génération augmentée de récupération (RAG)

Le RAG, introduit par Lewis et al. [15], consiste à coupler un modèle de recherche documentaire à un modèle génératif : au moment de répondre, les passages les plus pertinents d’une base documentaire sont retrouvés puis injectés dans le contexte fourni au générateur. Cette approche évite de réentraîner le modèle à chaque mise à jour de la base de connaissances, et permet en principe de citer explicitement la source utilisée. La recherche documentaire elle-même s’appuie soit sur des représentations denses obtenues par un modèle d’embedding [14], soit sur des méthodes lexicales classiques comme BM25, soit sur une combinaison des deux. Un état de l’art récent [9] recense de nombreuses variantes plus avancées, comme le RAG auto-réflexif [1] qui apprend au modèle à décider lui-même quand et quoi récupérer. Notre propre pipeline, plus proche du RAG dit « naïf », est décrit en section 7.

4.3 Comparaisons existantes entre RAG et fine-tuning

Notre travail se positionne directement par rapport à l'étude Derby LLM de Bouvard, Ciancone, Gourru et Schaeffer [3], menée conjointement par l'entreprise Wikit et le Laboratoire Hubert Curien. Cette étude compare RAG et fine-tuning sur deux corpus d'entreprise français issus de sites web (le département de la Drôme et l'école Télécom Saint-Étienne), avec le même modèle de base que nous, Mistral 7B. Leur fine-tuning procède par poursuite du pré-entraînement (continuation de la tâche de prédiction du prochain mot directement sur les documents du domaine, sans reformulation en paires question-réponse), tandis que leur RAG s'appuie sur une solution commerciale (Wikit Semantics) et sur les embeddings `text-embedding-ada-002` d'OpenAI. Leur évaluation combine une arène à l'aveugle entre trois annotateurs, un jugement automatique de pertinence par LLM, et une métrique de fidélité déterministe fondée sur le recouvrement d'entités nommées extraites par spaCy. Leur conclusion principale est nette : le RAG est très largement préféré par les annotateurs humains (autour de 67 % contre 3 % pour le fine-tuning selon le jeu de données), et le fine-tuning par poursuite du pré-entraînement peine à injecter des connaissances nouvelles de manière fiable, produisant parfois du texte plausible mais factuellement faux.

Notre protocole reprend délibérément les mêmes familles de métriques (arène par paires, fidélité par recouvrement d'entités spaCy) pour permettre une comparaison directe, mais s'en distingue sur un point méthodologique important : notre fine-tuning est *supervisé*, sur des paires question-réponse formatées avec citation d'article, et non une poursuite non supervisée du pré-entraînement sur du texte brut. Cette distinction rejoint directement les travaux d'Ovadia et al. [20], qui montrent que le RAG surpasse systématiquement le fine-tuning non supervisé pour l'injection de connaissances factuelles : c'est exactement la limite que rencontre Derby LLM avec son propre fine-tuning. En utilisant un fine-tuning supervisé, plus proche de l'usage pour lequel QLoRA a été conçu, nous testons si cette limite tient encore. Il est notable que Derby LLM identifie elle-même, dans ses perspectives de travaux futurs, la mise en forme du fine-tuning comme une tâche d'instruction plutôt que de poursuite de pré-entraînement : c'est précisément ce que nous mettons en œuvre ici, ce qui fait de ce travail un prolongement direct de leurs perspectives plutôt qu'une simple reproduction.

Un troisième point de comparaison vient de Balaquer et al. [2], qui étudient un cas d'usage agricole et montrent que le fine-tuning seul peut apporter un gain de précision substantiel (+6 points), et que combiner fine-tuning et RAG en ajoute encore (+5 points supplémentaires) plutôt que les deux techniques ne se recouvrent. Nos propres résultats (section 8) vont dans le même sens sur la configuration combinée, ce qui constitue un point de convergence entre deux domaines d'application très différents.

4.4 Évaluation des systèmes de question-réponse génératifs

L'évaluation d'un texte généré par un LLM reste un problème ouvert. Les métriques de similarité de surface comme ROUGE [16] comptent le recouvrement de sous-séquences de mots entre un texte généré et une référence, ce qui est simple et reproductible mais ne capture pas la paraphrase. BERTScore [25] corrige partiellement ce défaut en comparant des représentations contextuelles plutôt que des chaînes de caractères exactes. Des outils plus récents comme RAGAS [8] proposent d'évaluer spécifiquement les systèmes RAG en décomposant la qualité en plusieurs facettes (pertinence, fidélité au contexte, etc.), généralement calculées en confiant à un LLM l'extraction d'affirmations (*claims*) individuelles puis leur vérification. Notre propre métrique de fidélité, plus simple et entièrement déterministe (recouvrement d'entités nommées, de nombres et de coordonnées extraites par spaCy, à la manière de Derby LLM), est assumée comme une simplification volontaire plutôt que présentée comme équivalente à une approche comme RAGAS.

L'évaluation humaine par comparaison directe de paires de réponses, popularisée à grande échelle par Chatbot Arena [6], offre un signal plus proche de l'usage réel mais est coûteuse à collecter et sujette à un accord inter-annotateurs imparfait. La méthode de classement associée, le modèle de Bradley-Terry, transforme un ensemble de votes par paires en un score de force relative sur une échelle unique ; nous la réutilisons pour notre propre arène (section 8.9). Enfin, l'utilisation d'un LLM comme juge introduit ses propres biais connus, en particulier un biais d'auto-préférence lorsque le juge est aussi l'un des systèmes évalués, un point que nous avons pris soin d'éviter dans notre propre protocole. Au-delà de l'évaluation de la qualité, la question du coût pratique d'exécution des LLM à différentes tailles est également documentée dans la littérature [24], et le

problème plus général de l'hallucination fait l'objet d'un état de l'art dédié [21].

4.5 Corpus et bancs d'essai juridiques

Plusieurs bancs d'essai juridiques existent dans la littérature, essentiellement en anglais : LegalBench [10] rassemble une collection de tâches de raisonnement juridique construites collaborativement, CUAD [11] porte sur l'analyse de contrats, et LexGLUE [4] propose un ensemble de tâches de compréhension du langage juridique. Pour le français, BSARD [17] propose un corpus de recherche d'articles de loi belges francophones, que nous décrivons en détail en section 5. Son prolongement naturel, LLeQA [18], ajoute des réponses rédigées et des annotations enrichies sur ce même corpus : c'était notre cible initiale, mais l'accès n'a jamais été accordé malgré une demande, ce qui a justifié la bascule vers BSARD (section 5).

4.6 Modèles de base

Nous utilisons Mistral-7B-Instruct [13], un modèle ouvert de 7 milliards de paramètres qui offre un bon compromis entre qualité et coût d'exécution sur un budget de calcul limité, et le même choix que Derby LLM, ce qui facilite la comparaison. Nous testons également la généralisation de nos observations à un second modèle de taille comparable, Qwen2.5-7B-Instruct (section 8.13). D'autres familles ouvertes comme Llama 2 [22] auraient pu être considérées, mais n'ont pas été retenues faute de budget de calcul supplémentaire. Tous ces modèles reposent sur l'architecture Transformer [23] et sont alignés par instruction-tuning à la suite d'InstructGPT [19].

5. Données et méthodologie des données

5.1 BSARD

BSARD (*Belgian Statutory Article Retrieval Dataset*) [17] est un corpus public de droit belge francophone, composé de 22 633 articles de loi (14 167 fédéraux, 8 466 régionaux) et de questions annotées avec les identifiants des articles nécessaires pour y répondre. Le corpus est fourni avec un split d'entraînement de 886 questions, un split de test de 222 questions, et un split synthétique de 113 165 paraphrases générées automatiquement et non annotées à la main, que nous n'utilisons que ponctuellement (section 8.8). Chaque question porte un champ

category natif parmi sept catégories juridiques (Famille, Logement, Argent, Justice, Étrangers, Travail, Protection sociale), dont la répartition est fortement déséquilibrée (figure 1) : Famille et Logement dominent largement, tandis que Protection sociale ne compte que quatre questions dans le jeu de test.




Figure 1 – Répartition des questions de test BSARD par catégorie juridique.

Le choix du droit belge francophone plutôt que du droit français mérite d'être justifié explicitement : l'objet de ce travail est la comparaison de méthodes d'adaptation d'un modèle à un domaine, pas le contenu juridique français en tant que tel. La langue reste le français, la structure du problème (citer un article de loi précis pour répondre) est identique, et le blocage de l'accès à LLeQA (qui aurait offert un corpus français plus riche) rend BSARD le meilleur substitut disponible librement.

5.2 Une limite méthodologique assumée

BSARD est nativement un corpus de *recherche documentaire*, pas de question-réponse générative : il ne contient aucune réponse rédigée en langage naturel, seulement les identifiants des articles pertinents. La « réponse de référence » utilisée pour calculer ROUGE-L et BERTScore est donc reconstruite par concaténation du texte des articles cités. Cette reconstruction n'est pas une réponse idéale telle qu'un juriste l'aurait rédigée : les scores de similarité de surface doivent donc être lus comme une mesure de *recouvrement lexical avec le texte de loi*, pas comme une mesure de qualité rédactionnelle. Cette limite explique en grande partie pourquoi tous les scores ROUGE-L observés dans ce rapport restent relativement bas (entre 0,08 et 0,18) sans que cela ne signifie que les réponses soient inutilisables.

6. Techniques classiques d'évaluation des outils d'IA générative

Avant de décrire nos propres choix, il est utile de rappeler le panorama des familles de méthodes disponibles pour évaluer un système de génération de texte, avec leurs limites respectives.

Les **métriques de similarité lexicale** (BLEU, ROUGE [16]) comparent des sous-séquences de mots entre le texte généré et une référence. Elles sont rapides, reproductibles et ne nécessitent aucun modèle supplémentaire, mais pénalisent injustement une reformulation correcte qui n'utilise pas les mêmes mots que la référence.

Les **métriques fondées sur des embeddings** comme BERTScore [25] comparent des représentations contextuelles plutôt que des chaînes exactes, ce qui corrige partiellement ce problème, au prix d'un calcul plus coûteux et d'une interprétation moins directe.

L'**évaluation humaine par arène** (comparaison à l'aveugle de deux réponses, avec ou sans classement Elo/Bradley-Terry [6]) donne le signal le plus proche d'un usage réel, mais est coûteuse à collecter, lente, et nécessite plusieurs annotateurs pour être fiable (l'accord inter-annotateurs devant lui-même être mesuré, pas supposé).

Le **LLM-as-judge**, utilisé par exemple dans RAGAS [8], remplace l'annotateur humain par un modèle de langage instruit pour noter les réponses. C'est rapide et peu coûteux à grande échelle, mais introduit des biais documentés : un biais d'auto-préférence si le juge est aussi l'un des systèmes comparés, un biais de position (favoriser la réponse présentée en premier), et une instabilité d'un jugement à l'autre pour la même paire question-réponse si le juge n'est pas interrogé de façon totalement déterministe.

Notre propre protocole (section 7) combine plusieurs de ces familles plutôt que de n'en retenir qu'une seule, précisément parce qu'aucune n'est suffisante isolément.

7. Contribution méthodologique

7.1 Quatre configurations comparées

Nous comparons quatre configurations, résumées dans le tableau 1. Le même prompt système, en

Table 1 – Description des quatre configurations comparées.

Config	Description	Retrieval	F
C1	Mistral-7B-Instruct zero-shot	Non	
C2	RAG (retrieval e5-large + reranker)	Oui	
C3	Fine-tuning QLoRA seul	Non	
C4	Fine-tuning QLoRA + RAG	Oui	

français, est utilisé dans les quatre cas pour garantir une comparaison équitable : il demande une réponse claire, rédigée, appuyée sur le contexte fourni le cas échéant, se terminant impérativement par une citation d'article au format « Article <numéro> », et invite explicitement le modèle à répondre « Je ne sais pas » plutôt que d'inventer une réponse s'il n'a pas assez d'éléments pour répondre avec certitude.

7.2 Pipeline de recherche documentaire (RAG)

La recherche documentaire combine un index dense, construit avec le modèle d'embedding multilingue `multilingual-e5-large`, et un index lexical BM25, fusionnés par fusion de rang réciproque (*reciprocal rank fusion*). Un rerankeur à cross-encodeur, `BAAI/bge-reranker-v2-m3` [5], peut ensuite réordonner les candidats retrouvés. Par défaut, les cinq articles les mieux classés sont injectés dans le prompt du générateur (figure 2).




Figure 2 – Pipeline de recherche documentaire hybride utilisé pour le RAG.

7.3 Fine-tuning QLoRA

Le fine-tuning gèle le modèle de base, quantifié en 4 bits (format NF4), et entraîne un adaptateur LoRA de rang 32 sur les matrices d'attention (`q_proj`, `k_proj`, `v_proj`, `o_proj`), soit environ 0,375 % des paramètres totaux du modèle. L'entraînement principal utilise 580 exemples question-réponse-citation construits à partir du split d'en-

entraînement de BSARD, sur trois époques, avec un taux d'apprentissage de 2×10^{-4} . Cent questions supplémentaires, tirées avec une graine fixe indépendante de la graine d'entraînement, sont réservées pour la validation, de façon identique et disjointe quelle que soit la variante testée : ce jeu de validation fixe permet de comparer objectivement les différentes ablations (rang, cibles, taille de train) sur un signal de généralisation plutôt que sur la seule perte d'entraînement.

7.4 Protocole statistique

Contrairement à une comparaison sur un petit échantillon avec un seul chiffre par configuration, nous évaluons chaque configuration sur l'ensemble des 222 questions de test, et accompagnons chaque score moyen d'un intervalle de confiance à 95 % obtenu par rééchantillonnage bootstrap (1000 rééchantillonnages). Pour chaque paire de configurations, nous appliquons deux tests de significativité différents : un test bootstrap apparié, qui ne suppose rien sur la distribution des différences, et un test de Wilcoxon signé, fondé sur les rangs. Lorsque les deux tests s'accordent, la conclusion est traitée comme plus solide ; lorsqu'ils divergent, la comparaison est traitée comme non tranchée plutôt que de choisir le résultat le plus favorable. Une correction de Holm-Bonferroni est appliquée pour tenir compte du fait de tester six paires à la fois. Notons que Derby LLM [3] ne rapporte ni intervalle de confiance ni test de significativité sur ses propres chiffres : notre protocole va délibérément plus loin sur ce point.

8. Résultats

8.1 Recherche documentaire

Le tableau 2 compare les quatre méthodes de recherche sur les 222 questions de test. Le passage d'un modèle d'embedding généraliste (*mpnet*) à un modèle multilingue plus large (*e5-large*) améliore fortement le Recall@1, qui passe de 0,021 à 0,083. BM25, une méthode purement lexicale sans aucun apprentissage, fait étonnamment mieux que le modèle d'embedding généraliste initial, ce qui suggère que le vocabulaire juridique spécifique est mal couvert par des embeddings entraînés sur du texte généraliste. La combinaison hybride BM25+e5-large améliore encore chaque score par rapport à la meilleure méthode individuelle.

Même avec la meilleure combinaison, le bon article

Table 2 – Comparaison des méthodes de retrieval sur les 222 questions test de BSARD.

Méthode	Recall@1	Recall@3	Recall@5	Re
BM25	0.063	0.140	0.184	
mpnet (baseline)	0.021	0.045	0.074	
multilingual-e5-large	0.083	0.169	0.211	
Hybride (RRF)	0.106	0.196	0.250	

manque encore dans plus de deux cas sur trois parmi les dix premiers résultats (Recall@10 = 0,322). Une ablation complémentaire (section 8.8) montre qu'un rerankeur cross-encodeur améliore encore ce chiffre, mais la recherche documentaire reste la première source d'erreur de tout le pipeline RAG (section 8.5).

8.2 Comparaison des quatre configurations

Le tableau 3 et la figure 3 présentent la comparaison principale. L'ajout du RAG seul (C2) ou du fine-tuning seul (C3) améliore chacun nettement la qualité par rapport à l'absence d'adaptation (C1), et la combinaison des deux (C4) fait encore mieux.

Config.	ROUGE-L	IC 95 %
C1 – zero-shot	0,110	[0,104 ; 0,116]
C2 – RAG	0,140	[0,129 ; 0,151]
C3 – fine-tune	0,147	[0,136 ; 0,160]
C4 – fine-tune+RAG	0,179	[0,157 ; 0,202]

Table 3 – ROUGE-L moyen avec intervalles de confiance bootstrap à 95 %, sur les 222 questions de test complètes.




Figure 3 – ROUGE-L avec intervalles de confiance pour les quatre configurations.

Les tests de significativité appariés (tableau 4) nuancent cependant ce classement brut. La différence entre C2 (RAG seul) et C3 (fine-tuning seul) n'est **pas** signifi-

Table 5 – Fiabilité des réponses : exactitude de citation et hallucination (222 questions test).

Config	Précision citation	Rappel citation
C1_zero_shot	0.016	0.011
C2_rag	0.176	0.132
C3_finetune	0.023	0.012
C4_finetune_rag	0.069	0.053

cative, les deux tests s'accordant là-dessus : contrairement à ce que suggèrent les moyennes brutes du tableau 3, RAG et fine-tuning sont statistiquement indiscernables l'un de l'autre sur ROUGE-L. La comparaison entre C3 et C4 est le seul cas où les deux tests ne s'accordent pas (le bootstrap la juge significative, Wilcoxon non), et est donc traitée ici comme non tranchée plutôt que présentée comme acquise.

Comparaison	<i>p</i> (bootstrap)	<i>p</i> (Wilcoxon)	Sig.
C1 vs C2	0,000	0,000	oui
C1 vs C3	0,000	0,000	oui
C1 vs C4	0,000	0,000	oui
C2 vs C3	0,296	0,080	non
C2 vs C4	0,000	0,000	oui
C3 vs C4	0,004	0,307	non tranché

Table 4 – Tests de significativité appariés (bootstrap et Wilcoxon), correction de Holm-Bonferroni appliquée.


8.3 Fiabilité : exactitude de citation et hallucination

Puisque la citation d'article est au cœur du sujet, le tableau 5 regarde ce chiffre séparément du recouvrement lexical global. Le RAG (C2) a de loin la meilleure exactitude de citation (correspondance exacte 3,6 %, contre 0,5 % pour C1 et 0,0 % pour C3), ce qui est logique : le RAG a accès au texte réel de l'article au moment de répondre. En revanche, le fine-tuning seul (C3) obtient le taux d'hallucination le plus bas des quatre configurations (5,0 %), presque trois fois moins que le RAG (23,4 %). Autrement dit, le fine-tuning apprend à être prudent (il invente moins de références), mais sans pour autant citer souvent la bonne, tandis que le RAG cite plus souvent juste mais hallucine aussi plus souvent lorsqu'il se trompe.

8.4 Analyse par catégorie juridique

La figure 4 décompose le ROUGE-L par catégorie juridique et par configuration. Le classement global des quatre configurations se maintient globalement

à travers les catégories, mais avec des écarts d'amplitude notables : Logement montre le plus grand écart entre C1 et C4 (0,118 à 0,216), tandis que Protection sociale, la catégorie la plus rare (4 questions de test seulement), reste peu concluante à cause de la taille de l'échantillon.

**Figure 4** – ROUGE-L par configuration et catégorie juridique.

8.5 D'où vient l'erreur restante : expérience de contexte oracle

Pour décomposer l'erreur totale du RAG entre erreur de recherche et erreur de génération, nous avons mené une expérience où les vrais articles pertinents sont placés directement dans le prompt, sans passer par le moteur de recherche (tableau 6). Cette condition « oracle » retire complètement l'erreur de recherche.

Condition	ROUGE-L	Exact match	Halluc.
C1 – sans contexte	0,110	0,005	0,144
C2 – RAG réel	0,140	0,036	0,234
Contexte oracle	0,252	0,311	0,117

Table 6 – Décomposition de l'erreur : contexte oracle vs recherche réelle, modèle de base dans les trois cas.

L'écart entre recherche réelle et contexte oracle est très net sur l'exactitude de citation (0,036 contre 0,311, un écart de 0,275), nettement plus grand que l'écart entre recherche réelle et absence totale de contexte. L'essentiel de ce qui manque aujourd'hui vient donc de la recherche documentaire qui ne trouve pas le bon article, plutôt que du modèle qui échouerait à exploiter un bon article une fois qu'il l'a. Un résultat moins attendu apparaît aussi : le taux d'hallucination est plus élevé avec la recherche réelle (0,234) qu'avec aucun contexte du tout (0,144),

Table 7 – Capacité d’abstention (50 questions hors-domaine/sans réponse).

Config	Taux d’abstention correcte
C1_zero_shot	0.000
C2_rag	0.020

alors qu’il redescend sous contexte oracle (0,117). Un article plausible mais faux semble inviter le modèle à une invention plus confiante qu’une absence totale d’information.

8.6 Le système connaît-il ses propres limites ? Capacité d’abstention

Aucune des mesures précédentes ne dit si le système sait reconnaître qu’il ne devrait pas répondre. Un ensemble de 50 questions hors du champ de compétence du système a été construit à cet effet : des questions sans aucun contenu juridique, des questions sur un droit étranger que BSARD ne couvre pas, et des questions faisant référence à un article retiré de l’index. Le tableau 7 montre le taux d’abstention correcte (le système répond bien « Je ne sais pas » plutôt que d’inventer une réponse).

Le résultat est sans appel : le système ne s’abstient presque jamais. Même pour une question totalement étrangère au droit (par exemple une recette de cuisine), il produit une réponse d’apparence confiante, numéros d’article inventés inclus, dans la quasi-totalité des cas. C’est l’une des faiblesses les plus nettes de ce travail, et aucune des deux techniques testées ne la corrige d’elle-même.

8.7 Coût pratique

Le tableau 8 résume le coût pratique de chaque configuration. Le fine-tuning ajoute un coût d’entraînement ponctuel mais faible (environ 15 minutes pour la configuration principale, grâce à QLoRA), tandis que le RAG ajoute un coût récurrent à chaque génération (la recherche documentaire et le contexte supplémentaire ralentissent l’inférence, environ 2,4 fois plus lente pour C2 que pour C1).

8.8 Ablations

8.8.1 Profondeur de recherche (k)

Une ablation sur le nombre d’articles injectés dans le prompt (tableau 9, sur un échantillon de 50 questions) montre un optimum autour de $k = 3$: au-delà, la qualité ne progresse plus malgré un contexte beau-

Table 8 – Coût pratique par configuration.

Config	Durée génération (s, 222 q.)
C1_zero_shot	258.3
C2_rag	622.2
C3_finetune	343.4
C4_finetune_rag	705.5
Fine-tuning (entraînement)	0.25 h

coup plus long, et l’exactitude de citation redescend même, ce qui suggère qu’un contexte trop long rend l’article pertinent plus difficile à repérer plutôt que plus facile.

k	ROUGE-L	Cit. exacte	Halluc.	Ctx (car.)
1	0,135	0,020	0,140	1170
3	0,150	0,040	0,240	3531
10	0,136	0,020	0,200	12141

Table 9 – Ablation de la profondeur de recherche k , 50 questions, modèle de base.

8.8.2 Enrichissement et découpage du corpus

Le tableau 10 compare quatre variantes de recherche documentée. Enrichir chaque fragment avec ses métadonnées hiérarchiques (code, chapitre, section) améliore nettement le Recall@1 (0,083 à 0,119), ce qui confirme qu’une partie de la difficulté initiale venait d’un manque de signal lexical plutôt que d’une limite dure du corpus. Le découpage en fragments plus fins (256 tokens, 27 540 fragments au total) n’apporte pas de gain net par rapport à l’article entier. Le reranker cross-encodeur est la variante la plus efficace, avec un Recall@1 de 0,151, près du double de la base.

Variante	R@1	R@10	MRR@10
Base (e5-large)	0,083	0,296	0,288
+ Métadonnées	0,119	0,363	0,334
Découpage 256	0,083	0,330	0,306
+ Reranker	0,151	0,353	0,396

Table 10 – Ablation retrieval : enrichissement, découpage, reranking.

8.8.3 Rang LoRA, cibles, et taille de l’entraînement

Le tableau 11 résume les principales variantes de fine-tuning testées. Augmenter la taille du jeu d’entraînement améliore régulièrement la perte de validation. Étendre l’adaptateur aux couches de réseau

direct en plus de l’attention (attn+MLP) fait nettement baisser la perte de validation, mais l’écart entre perte d’entraînement et perte de validation grandit également, un signe de surapprentissage plus marqué. La figure 5 illustre la courbe d’apprentissage complète.

Variante	n	Perte train	Perte val.
Principale ($r=32$)	580	0,834	0,679
Rang $r=8$	580	0,850	0,710
$n = 190$	190	1,122	1,098
$n = 380$	380	0,966	0,860
$n = 786$	786	0,736	0,561
Attn + MLP	580	0,527	0,416
+ Données synthétiques	2580	0,940	0,516

Table 11 – Variantes de fine-tuning, trois époques chacune, même graine.




Figure 5 – Courbe d’apprentissage : perte de validation selon la taille du jeu d’entraînement.

8.8.4 Variance entre graines aléatoires

La configuration principale de fine-tuning a été répétée sur trois graines (42, 123, 2026), en réponse directe à la remarque d’A. Habrard qu’une seule expérience n’est pas suffisante pour un binôme. La perte d’entraînement finale est stable ($0,843 \pm 0,006$), mais la qualité des réponses réellement générées varie davantage : pour C3, le ROUGE-L moyen sur les trois graines est de $0,153 \pm 0,005$ et le taux d’hallucination de $0,077 \pm 0,019$ (contre $0,050$ pour la seule graine principale rapportée dans le tableau 5, qui sous-estime donc ce taux). Pour C4, le ROUGE-L moyen est de $0,166 \pm 0,012$: la graine principale ($0,179$, rapportée dans le tableau 3) est en fait la plus favorable des trois, pas la moyenne. Sur ROUGE-L, C4 ne bat C3 que sur deux des trois graines : la supériorité de la configuration combinée, bien que réelle en moyenne, n’est donc pas systématique et doit être nuancée plutôt que présentée comme ac-

quise dans l’absolu. Les configurations C1 et C2, qui ne dépendent d’aucun entraînement et utilisent un décodage glouton (température nulle), sont par construction identiques à travers les trois graines.

8.8.5 Spécialiste d’un domaine juridique unique

Pour tester si un adaptateur entraîné sur un seul domaine fait mieux sur ce domaine qu’un adaptateur généraliste, un adaptateur « spécialiste » a été entraîné uniquement sur les questions touchant au Code Civil (331 exemples, contre 580 pour le généraliste). Sur son propre domaine, le spécialiste (C3) est légèrement meilleur en ROUGE-L ($0,181$ contre $0,171$) mais hallucine nettement plus ($15,1\%$ contre $4,7\%$). Combiné au RAG (C4), il fait moins bien que le généraliste dans les deux domaines, tout en hallucinant moins dans les deux. Ces résultats sont mitigés plutôt que tranchés, et se lisent difficilement sans tenir compte du fait que le spécialiste dispose de moins d’exemples d’entraînement que le généraliste : cette expérience mélange donc l’effet de la restriction de domaine avec l’effet de la taille d’entraînement, et ne permet pas de trancher seule si la spécialisation par domaine aide.

8.9 Évaluation humaine

Toute mesure présentée jusqu’ici est automatique. Trois annotateurs (les deux auteurs du TER et un troisième annotateur volontaire) ont comparé à l’aveugle les réponses de C2 (RAG) et de C3 (fine-tuning seul) sur 60 questions communes, sans savoir quelle réponse venait de quelle configuration, selon un tirage stratifié par catégorie juridique pour éviter de reproduire le déséquilibre du corpus.

L’accord inter-annotateurs, mesuré par le Kappa de Cohen sur chaque paire d’annotateurs, est modéré : $0,389$ entre les deux premiers annotateurs, $0,471$ et $0,331$ pour les deux paires impliquant le troisième (tableau 12). À titre de comparaison, Derby LLM rapporte un accord un peu plus élevé sur ses propres annotateurs (Kappa entre $0,539$ et $0,577$) : notre tâche semble donc un peu plus subjective ou ambiguë que la leur, ce qui est rapporté honnêtement plutôt que supposé équivalent.

Paire	Kappa	Accord exact
Annotateur 1 vs 2	0,389	56,7 %
Annotateur 1 vs 3	0,471	66,7 %
Annotateur 2 vs 3	0,331	53,3 %

Table 12 – Accord inter-annotateurs (Kappa de Cohen), arène C2 vs C3, 60 questions.

Malgré cet accord modéré, les trois annotateurs préfèrent indépendamment et très majoritairement le RAG (C2) au fine-tuning seul (C3). Un classement par modèle de Bradley-Terry [6], calculé à partir de l'ensemble des 161 votes exploitables (les votes « aucune réponse n'est bonne » sont exclus), donne un score de force relative de 1369 pour C2 contre 631 pour C3 sur une échelle de type Elo (figure 6).




Figure 6 – Classement Bradley-Terry, arène C2 vs C3, 3 annotateurs.

Cette préférence humaine nette pour le RAG se retrouve dans toutes les catégories juridiques (tableau 13), avec un écart particulièrement marqué sur Famille (86,7 % contre 6,7 %) et le plus faible sur Protection sociale (50,0 % contre 8,3 %, sur un échantillon réduit de 12 votes).

Catégorie	<i>n</i>	% C2	% C3
Famille	30	86,7	6,7
Argent	30	76,7	3,3
Justice	30	70,0	3,3
Travail	18	72,2	0,0
Logement	30	66,7	6,7
Étrangers	30	60,0	20,0
Protection sociale	12	50,0	8,3

Table 13 – Préférence humaine C2 vs C3 par catégorie, 3 annotateurs combinés.

Enfin, sur les 60 questions communes aux trois annotateurs, 45,0 % recueillent un accord unanime (les

trois préfèrent la même réponse), 41,7 % un accord majoritaire (deux sur trois), et seulement 13,3 % aucun accord : le désaccord observé plus haut est donc rare et jamais total, plutôt que systématique.

Ce résultat entre en tension directe avec la comparaison automatique de la section précédente, qui ne trouvait *pas* de différence significative entre C2 et C3 sur ROUGE-L. Plutôt qu'une contradiction à résoudre, cet écart illustre concrètement pourquoi une métrique de surface et un jugement humain à l'aveugle ne vont pas toujours dans le même sens, et justifie de les mesurer côte à côte plutôt que de se fier à un seul type de signal (section 6).

8.10 Fidélité et jugement automatique de pertinence

En complément des mesures ci-dessus, une métrique de fidélité déterministe (recouvrement d'entités nommées et de nombres extraits par spaCy, à la manière de Derby LLM) et un jugement de pertinence par un LLM indépendant (Phi-3.5-mini-instruct, choisi précisément parce qu'il n'est ni l'un des systèmes comparés ni le second modèle de base testé, pour éviter tout biais d'auto-préférence) sont présentés dans le tableau 14. Chaque réponse est notée dix fois par le juge à température non nulle et les scores sont moyennés, un jugement unique et déterministe étant trop instable pour être fiable.

Config.	Fidélité	Pertinence /5
C1 – zero-shot	0,054	5,00
C2 – RAG	0,295	4,85
C3 – fine-tune	0,298	4,73
C4 – fine-tune+RAG	0,324	4,62

Table 14 – Fidélité au texte de référence et pertinence jugée par LLM.




Figure 7 – Distribution des scores de pertinence jugée par configuration.

Le score moyen de pertinence reste élevé et presque

plat à travers les quatre configurations, mais la moyenne masque une tendance : la part de réponses jugées clairement hors sujet augmente régulièrement de C1 vers C4 (figure 7). Lu avec l’analyse qualitative de la section 9, ce constat suggère que le RAG et le fine-tuning éloignent parfois la réponse de la question réellement posée, un effet réel mais nettement plus petit que l’écart d’ancrage des citations.

8.11 Ce qui rend une question difficile

Deux hypothèses ont été testées directement pour expliquer pourquoi certaines questions obtiennent de meilleures réponses que d’autres : la longueur de la question, et le nombre d’articles de loi nécessaires pour y répondre correctement. La longueur de la question n’a quasiment aucun lien avec la qualité de la réponse (corrélation de Spearman non significative dans trois configurations sur quatre). Le nombre d’articles nécessaires, en revanche, corrèle négativement et de façon hautement significative avec la qualité dans les quatre configurations sans exception ($p < 0,0001$ partout, coefficients entre $-0,34$ et $-0,51$). La figure 8 montre que la qualité chute nettement dès que quatre articles ou plus sont nécessaires, dans chaque configuration : ni le RAG ni le fine-tuning ne corrigent ce problème structurel d’eux-mêmes.




Figure 8 – ROUGE-L regroupé par nombre d’articles requis pour répondre.

8.12 Prédiction supervisée de la fiabilité

Au-delà de comparer les configurations entre elles, nous avons cherché à savoir si le risque qu’une réponse soit peu fiable (citation incorrecte) peut être prédit à partir de caractéristiques observables avant même la génération : longueur de la question, nombre d’articles gold, catégorie, régularité du format d’identifiant, et configuration utilisée. Un classifieur de régression logistique et une Forêt Aléa-

toire sont entraînés sur 888 observations (222 questions $\times$ 4 configurations), avec validation croisée à 5 plis stratifiée vu le déséquilibre marqué de la cible (seulement 1,1 % de citations exactement correctes).

Les deux modèles font nettement mieux qu’un classifieur naïf qui prédirait toujours la classe majoritaire ($AUC = 0,50$) : 0,878 pour la régression logistique, 0,838 pour la Forêt Aléatoire (figure 9). L’importance des variables dans la Forêt Aléatoire (figure 10) montre que la longueur de la question domine (0,389), suivie de la fréquence de la catégorie dans le train (0,185) et du nombre d’articles gold (0,158) : la configuration utilisée (C1 à C4) ne compte au total que pour environ 0,20 de l’importance cumulée, moins que les caractéristiques de la question elle-même. Autrement dit, la difficulté intrinsèque de la question pèse davantage sur la fiabilité de la réponse que le choix entre RAG et fine-tuning.




Figure 9 – Courbes ROC des deux classifieurs de fiabilité.




Figure 10 – Importance des variables, Forêt Aléatoire.

8.13 Généralisation à un second modèle de base

Pour vérifier que nos observations ne sont pas une particularité de Mistral, le protocole C1/C2 a été reproduit avec Qwen2.5-7B-Instruct à la place. Les tendances se confirment : le RAG améliore le ROUGE-L (0,105 à 0,131) exactement comme avec Mistral, mais le taux d'hallucination augmente aussi fortement avec le RAG (18,0 % à 36,0 %), une augmentation encore plus marquée que pour Mistral (14,4 % à 23,4 %). Le phénomène observé en section 8.5 – le RAG améliore la qualité globale tout en augmentant le risque d'hallucination – n'est donc pas propre à un seul modèle.

9. Analyse qualitative des erreurs

Au-delà des chiffres, la lecture directe des réponses annotées fait ressortir des schémas d'erreur récurrents.

L'erreur la plus fréquente est une **inversion de rôle juridique** : une obligation attribuée à la mauvaise partie, souvent sur des paires de questions qui ne diffèrent que d'un mot (par exemple « marié » contre « cohabitant légal »), où le bon article diffère d'une façon subtile facile à manquer aussi bien pour la recherche que pour la génération.

Le **texte de loi inventé** apparaît aussi assez souvent. Étant donné que l'hallucination ne disparaît pas complètement même sous contexte oracle (section 8.5), une partie au moins de ce phénomène semble être une tendance générale du modèle de base plutôt qu'une simple conséquence d'une mauvaise recherche.

Un nombre plus restreint de réponses **dérivent de**

la question posée, généralement lorsqu'un passage retrouvé est proche du sujet sans vraiment y répondre : c'est ce schéma qui explique la lente dégradation de la pertinence jugée observée en section précédente.

Enfin, un dernier schéma de **texte répété ou coupé** dans certaines réponses ressemble davantage à un problème de réglage du décodage qu'à une limite du modèle lui-même, puisque la génération n'utilise actuellement aucune pénalité de répétition explicite.

10. Discussion

10.1 Réponses aux questions de recherche

Sur la première question – un modèle spécialisé par fine-tuning peut-il rivaliser avec un modèle généraliste appuyé sur le RAG – la réponse est globalement oui sur les métriques automatiques (C3 n'est pas statistiquement distinguable de C2 sur ROUGE-L), mais nettement non du point de vue humain (section 8.9, où le RAG est très majoritairement préféré). C'est précisément le type d'écart que ce travail cherchait à mettre en évidence en mesurant les deux types de signal côte à côte.

Sur la deuxième question – le fine-tuning apporte-t-il un gain réel, et ce gain se maintient-il combiné au RAG – le fine-tuning seul améliore nettement le taux d'hallucination par rapport à toutes les autres configurations, ce qui est un gain réel et spécifique. Combiné au RAG, il améliore encore le ROUGE-L moyen, mais cette supériorité n'est confirmée ni par les tests de significativité (section 8) ni de façon systématique à travers les trois graines testées (section 8.8) : le gain existe en moyenne mais n'est pas garanti sur une seule exécution.

Sur la troisième question – le système sait-il citer sa source et reconnaître ses limites – la réponse est clairement non sur le second point : le taux d'abstention correcte sur des questions hors champ reste proche de zéro pour toutes les configurations testées (section 8), et c'est là le problème le plus sérieux de ce travail, plus que le choix entre RAG et fine-tuning.

10.2 Positionnement par rapport à Derby LLM

Comme Derby LLM [3], nous trouvons que le RAG est nettement préféré par les annotateurs humains

au fine-tuning seul, avec une ampleur d'écart comparable (autour de 70-80 % de préférence contre quelques pourcents seulement dans les deux études). Là où nos résultats divergent, c'est sur les métriques automatiques : Derby LLM trouve le RAG systématiquement meilleur que le fine-tuning sur la pertinence et la fidélité jugées, tandis que nous ne trouvons pas de différence significative entre RAG et fine-tuning sur ROUGE-L, et trouvons même le fine-tuning nettement meilleur sur le taux d'hallucination. L'explication la plus probable, discutée en section 4.3, est méthodologique : notre fine-tuning est supervisé sur des paires question-réponse, là où celui de Derby LLM est une poursuite non supervisée du pré-entraînement. Ce travail se lit ainsi comme une confirmation partielle de Derby LLM (le RAG reste préféré humainement) et comme un prolongement de leurs propres perspectives (un fine-tuning formaté en instruction change le tableau sur les métriques automatiques, sans changer la préférence humaine).

10.3 Limites

Plusieurs limites doivent être gardées en tête en lisant ces résultats. BSARD porte sur le droit belge francophone, pas français ; l'absence de réponse gold rédigée oblige à reconstruire une référence par concaténation d'articles, ce qui pèse sur l'interprétation des scores ROUGE-L/BERTScore (section 5) ; le budget GPU limité a contraint la taille des jeux d'entraînement (quelques centaines d'exemples) et le nombre de graines testées pour certaines ablations ; et l'accord inter-annotateurs de l'arène humaine, bien que rapporté honnêtement, reste modéré plutôt que fort.

11. Conclusion et perspectives

Ce travail compare le RAG et le fine-tuning QLoRA sur un assistant de question-réponse juridique en français, avec un protocole étendu par rapport à une comparaison sur petit échantillon : jeu de test complet, intervalles de confiance, tests appariés, dix ablations complémentaires, décomposition de l'erreur retrieval/génération, et évaluation humaine à trois annotateurs. Le RAG et le fine-tuning apportent chacun un gain net et distinct par rapport à l'absence d'adaptation : le RAG améliore surtout l'exactitude de citation, le fine-tuning améliore surtout la prudence face à l'invention. Les combiner améliore encore le résultat en moyenne, sans que ce

gain soit systématique d'une exécution à l'autre. Le problème le plus sérieux mis en évidence n'est pas un manque de qualité sur les bonnes questions, mais l'incapacité quasi totale du système à reconnaître les mauvaises.

Plusieurs pistes restent ouvertes pour un travail futur : un stress-test adversarial construit spécifiquement autour de références d'articles plausibles mais inexistantes, une extrapolation formelle de la courbe d'apprentissage pour estimer combien d'exemples supplémentaires seraient nécessaires pour rejoindre le niveau du contexte oracle, une analyse de puissance statistique explicite pour les sous-groupes les plus rares (Protection sociale), et surtout un travail ciblé sur la capacité d'abstention, probablement la piste la plus prometteuse au vu de l'ampleur du problème identifié.

Remerciements

Nous remercions François Jacquenet et Amaury Harbrard pour leur encadrement et leurs retours tout au long de ce travail, ainsi que le troisième annotateur volontaire pour sa participation à l'évaluation humaine.

Références

- [1] Akari Asai, Zeqiu Wu, Yizhong Wang, Avirup Sil, and Hannaneh Hajishirzi. Self-rag : Learning to retrieve, generate, and critique through self-reflection. *arXiv preprint arXiv :2310.11511*, 2023.
- [2] Angels Balaguer, Vinamra Benara, Renato Luiz de Freitas Cunha, Roberto de M. Estevão Filho, Todd Hendry, Daniel Holstein, Jennifer Marsman, Nick Mecklenburg, Sara Malvar, Leonardo O. Nunes, Rafael Padilha, Morris Sharp, Bruno Silva, Swati Sharma, Vijay Aski, and Ranveer Chandra. RAG vs fine-tuning : Pipelines, tradeoffs, and a case study on agriculture. *arXiv preprint arXiv :2401.08406*, 2024.
- [3] Christophe Bouvard, Mathieu Ciancone, Antoine Gourru, and Marion Schaeffer. Derby llm : Évaluation comparative des approches rag et fine-tuning. In *10ème Conférence Nationale sur les Applications Pratiques de l'Intelligence Artificielle (APIA@PFIA 2024)*, pages 38–47, La Rochelle, France, 2024. AFIA - Association

- Française pour l'Intelligence Artificielle. HAL : hal-04638460.
- [4] Ilias Chalkidis, Abhik Jana, Dirk Hartung, Michael Bommarito, Ion Androutsopoulos, Daniel Martin Katz, and Nikolaos Aletras. LexGLUE : A benchmark dataset for legal language understanding in english. In *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (ACL)*, 2022. arXiv :2110.00976.
 - [5] Jianlv Chen, Shitao Xiao, Peitian Zhang, Kun Luo, Defu Lian, and Zheng Liu. M3-embedding : Multi-linguality, multi-functionality, multi-granularity text embeddings through self-knowledge distillation. *arXiv preprint arXiv :2402.03216*, 2024.
 - [6] Wei-Lin Chiang, Lianmin Zheng, Ying Sheng, Anastasios Nikolas Angelopoulos, Tianle Li, Dacheng Li, Hao Zhang, Banghua Zhu, Michael Jordan, Joseph E. Gonzalez, and Ion Stoica. Chatbot arena : An open platform for evaluating LLMs by human preference. *arXiv preprint arXiv :2403.04132*, 2024.
 - [7] Tim Dettmers, Artidoro Pagnoni, Ari Holtzman, and Luke Zettlemoyer. Qlora : Efficient finetuning of quantized llms. *arXiv preprint arXiv :2305.14314*, 2023.
 - [8] Shahul Es, Jithin James, Luis Espinosa-Anke, and Steven Schockaert. Ragas : Automated evaluation of retrieval augmented generation. *arXiv preprint arXiv :2309.15217*, 2023.
 - [9] Yunfan Gao, Yun Xiong, Xinyu Gao, Kangxiang Jia, Jinliu Pan, Yuxi Bi, Yi Dai, Jiawei Sun, Meng Wang, and Haofen Wang. Retrieval-augmented generation for large language models : A survey. *arXiv preprint arXiv :2312.10997*, 2023.
 - [10] Neel Guha, Julian Nyarko, Daniel E. Ho, Christopher Ré, et al. Legalbench : A collaboratively built benchmark for measuring legal reasoning in large language models. *arXiv preprint arXiv :2308.11462*, 2023.
 - [11] Dan Hendrycks, Collin Burns, Anya Chen, and Spencer Ball. CUAD : An expert-annotated NLP dataset for legal contract review. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2021. arXiv :2103.06268.
 - [12] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. Lora : Low-rank adaptation of large language models. *arXiv preprint arXiv :2106.09685*, 2021.
 - [13] Albert Q. Jiang, Alexandre Sablayrolles, Arthur Mensch, Chris Bamford, Devendra Singh Chaplot, Diego de las Casas, Florian Bressand, Gianna Lengyel, Guillaume Lample, Lucile Saulnier, Léo Renard Lavaud, Marie-Anne Lachaux, Pierre Stock, Teven Le Scao, Thibaut Lavril, Thomas Wang, Timothée Lacroix, and William El Sayed. Mistral 7b. *arXiv preprint arXiv :2310.06825*, 2023.
 - [14] Vladimir Karpukhin, Barlas Oğuz, Sewon Min, Patrick Lewis, Ledell Wu, Sergey Edunov, Danqi Chen, and Wen-tau Yih. Dense passage retrieval for open-domain question answering. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2020. arXiv :2004.04906.
 - [15] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2020. arXiv :2005.11401.
 - [16] Chin-Yew Lin. ROUGE : A package for automatic evaluation of summaries. In *Text Summarization Branches Out*, pages 74–81, Barcelona, Spain, 2004. Association for Computational Linguistics.
 - [17] Antoine Louis and Gerasimos Spanakis. A statutory article retrieval dataset in french. In *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (ACL)*, 2022. arXiv :2108.11792.
 - [18] Antoine Louis, Gijs van Dijk, and Gerasimos Spanakis. Interpretable long-form legal question answering with retrieval-augmented large language models. *arXiv preprint arXiv :2309.17050*, 2023.
 - [19] Long Ouyang, Jeff Wu, Xu Jiang, Diogo Almeida, Carroll L. Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, John Schulman, Jacob Hilton, Fraser Kelton, Luke Miller, Maddie Simens, Amanda Askell, Peter Welinder, Paul Christiano, Jan Leike, and Ryan Lowe. Training language models to follow instructions with human feedback. *arXiv preprint arXiv :2203.02155*, 2022.
 - [20] Oded Ovadia, Menachem Brief, Moshik Mishaelli, and Oren Elisha. Fine-tuning or retrieval? comparing knowledge injection in llms. *arXiv preprint arXiv :2312.05934*, 2023.

- [21] Vipula Rawte, Amit Sheth, and Amitava Das. A survey of hallucination in large foundation models. *arXiv preprint arXiv :2309.05922*, 2023.
- [22] Hugo Touvron, Louis Martin, Kevin Stone, Peter Albert, Amjad Almahairi, others, and Thomas Scialom. Llama 2 : Open foundation and fine-tuned chat models. *arXiv preprint arXiv :2307.09288*, 2023.
- [23] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2017. arXiv :1706.03762.
- [24] Zhongwei Wan, Xin Wang, Che Liu, Samiul Alam, Yu Zheng, Jiachen Liu, Zhongnan Qu, Shen Yan, Yi Zhu, Quanlu Zhang, Mosharaf Chowdhury, and Mi Zhang. Efficient large language models : A survey. *arXiv preprint arXiv :2312.03863*, 2023.
- [25] Tianyi Zhang, Varsha Kishore, Felix Wu, Kilian Q. Weinberger, and Yoav Artzi. Bertscore : Evaluating text generation with BERT. In *International Conference on Learning Representations (ICLR)*, 2020. arXiv :1904.09675.

A. Annexe A – Difficultés techniques rencontrées

Cette annexe reprend, sous forme condensée, les principales difficultés techniques documentées au fil du projet (journal complet dans `DIFFICULTES.md` du dépôt de code), avec leur diagnostic et la solution retenue.

- **Accord d’accélérateur GPU par défaut.** Kaggle assigne par défaut un GPU Tesla P100, incompatible avec les versions récentes de PyTorch. Solution : forcer explicitement `machine_shape: NvidiaTeslaT4` dans les métadonnées du job.
- **Type de la colonne `article_ids`.** Ce champ de BSARD est une chaîne de caractères ("`947,948`"), pas une liste : un parsing manquant fait chuter silencieusement le Recall@k près de zéro sans erreur explicite.
- **Statut d’accès du modèle.** Le modèle Mistral-7B-Instruct-v0.3 a été supposé à tort nécessiter une acceptation de licence ; une vérification anonyme a confirmé qu’il est librement accessible sous licence Apache 2.0.
- **Absence de réponse gold dans BSARD.** Décrite en section 5, cette limite structurelle du corpus a été documentée avant la présentation des résultats plutôt que découverte a posteriori.
- **Évolution rapide de l’API `trl`.** La classe `SFTTrainer` a changé de signature entre versions (`TrainingArguments` remplacé par `SFTConfig`), et le mode de perte par défaut (`chunked_nll`) est incompatible avec un modèle quantifié et adapté par PEFT : forcer `loss_type="nll"` résout le problème.
- **Hétérogénéité des identifiants d’article.** Environ 32 % des identifiants d’article BSARD ne sont pas purement numériques (formats régionaux belges hétérogènes), et environ 2,5 % portent un suffixe d’annotation parasite collé par le scraping de la source. Les deux problèmes faussaient silencieusement les métriques de citation avant correction par expression régulière généralisée et nettoyage systématique.
- **Absence de sauvegarde incrémentale.** Plusieurs jobs d’ablation longs (reranking, profondeur k) ont perdu des résultats déjà calculés à cause d’un dépassement de mémoire GPU survenu avant la sauvegarde finale. Solution généralisée : sauvegarder après chaque étape indépendante, pas seulement à la fin du job.
- **Quota de sessions GPU Kaggle.** La limite de deux sessions GPU simultanées sur le compte gratuit a été dépassée à plusieurs reprises sans message d’erreur explicite, notamment parce qu’une nouvelle version poussée d’un kernel ne stoppe pas automatiquement la session précédente encore en cours.
- **Doublons dans les votes d’arène humaine.** Le fichier de votes d’un des trois annotateurs contenait quatre questions votées deux fois, probablement à la suite d’un rechargement de page en cours de session (la sauvegarde incrémentale n’empêche pas de revoter). Corrigé par déduplication systématique par identifiant de question, en conservant le vote le plus récent, avant tout calcul d’accord inter-annotateurs.

B. Annexe B – Détails d’implémentation

Configuration QLoRA complète. Rang $r = 32$, $\alpha = 32$, dropout 0,05, cibles `q_proj`, `k_proj`, `v_proj`, `o_proj`, quantification NF4 4 bits, trois époques, taille de batch 4 avec accumulation de gradient 4 (batch effectif 16), taux d’apprentissage 2×10^{-4} , modèle de base `mistralai/Mistral-7B-Instruct-v0.3` (miroir pré-quantifié `unsloth/mistral-7b-instruct-v0.3-bnb-4bit` utilisé pour réduire le temps de téléchargement).

Prompt système (identique aux quatre configurations).

Tu es un assistant juridique spécialisé en droit belge francophone. Réponds à la question posée en français, de manière claire et rédigée. Si un contexte juridique t’est fourni, appuie-toi dessus. Termine impérativement ta réponse par une citation précise de l’article sur lequel tu t’appuies, au format : « Article <numéro> ». Si tu ne

connais pas la réponse ou si le contexte ne permet pas de répondre avec certitude, réponds explicitement « Je ne sais pas » plutôt que d’inventer une réponse ou une référence.

Modèle d’embedding et reranker. `intfloat/multilingual-e5-large` pour la recherche dense (préfixes `query:/passage:`), `BAAI/bge-reranker-v2-m3` [5] pour le reranking cross-encodeur, `rank_bm25` (BM25Okapi) pour la recherche lexicale, fusion par rang réciproque ($k = 60$) pour l’hybride.

Juge LLM. `microsoft/Phi-3.5-mini-instruct`, choisi car absent des quatre configurations comparées et du second modèle de base testé (évite un biais d’auto-préférence), interrogé 10 fois par réponse à température > 0 , scores moyennés.