

Université Jean Monnet Saint-Étienne

TER – S2 2025/2026

**Conception et évaluation d'un assistant juridique fondé
sur l'IA,
étude comparative entre RAG et fine-tuning**

Rapport mensuel d'avancement – juillet/août 2026



Auteur

Chaabane Ouammou

M1 MLDM

Co-auteur : Bartosz Konior

M1 DSC

Encadrant : Amaury Habrard

1. L’objet de ce mois de travail

Le rapport précédent laissait le projet avec une première version fonctionnelle des deux pipelines et une seule comparaison entre eux, menée sur un petit échantillon de questions. Ce mois a été consacré à reprendre presque chaque partie de cette première version une par une, en vérifiant ce qui tenait toujours la route sous un examen plus attentif et ce qui ne tenait pas, et en construisant les éléments qui manquaient encore, en particulier une vraie comparaison statistique et une évaluation humaine. L’ordre ci-dessous suit à peu près l’ordre dans lequel le travail s’est réellement déroulé, en commençant par la recherche documentaire puisque tout le reste du pipeline RAG en dépend.

2. Reprendre la recherche documentaire

La recherche documentaire décide quels articles de loi le générateur voit jamais, donc avant de toucher à autre chose il semblait utile de vérifier à quel point elle était vraiment bonne. Le modèle d’embedding généraliste utilisé auparavant a été remplacé par un modèle multilingue plus large, **multilingual-e5-large**, et une base lexicale BM25 a été ajoutée à côté, avec une combinaison hybride simple des deux classements. L’idée était de voir dans quelle mesure la recherche faible observée avant venait vraiment d’une limite du jeu de données, et dans quelle mesure elle venait juste d’un modèle d’embedding pas assez fort.




Figure 1 – Pipeline de recherche documentaire. Le corpus est indexé une fois, une question est comparée à cet index au moment de la génération, et les articles retrouvés sont ajoutés au prompt.

Méthode	R@1	R@5	R@10
BM25	0.063	0.184	0.224
mpnet (avant)	0.021	0.074	0.097
e5-large	0.083	0.211	0.296
Hybride BM25+e5	0.106	0.250	0.322

Table 1 – Qualité de la recherche sur les 222 questions de test.

Le changement aide clairement, le Recall@1 triple à peu près et la combinaison hybride fait encore un peu mieux sur chaque score, donc la recherche faible observée avant venait au moins en partie du choix du modèle d’embedding plutôt que d’une limite dure du jeu de données. Même ainsi, le bon article manque encore plus de deux fois sur trois parmi les dix premiers résultats, ce qui n’est pas un petit écart et revient plus loin dans ce rapport.

3. Étendre les essais de fine-tuning

Le résultat de fine-tuning précédent venait d’un seul essai, ce qui laissait ouverte la question de savoir combien de ce résultat dépendait de la graine aléatoire particulière, ou de choix comme le rang de l’adaptateur ou la quantité de données d’entraînement utilisées. Ce mois, avec un ensemble d’entraînement un peu plus grand disponible, cet essai unique a été transformé en une petite famille d’essais qui changent un facteur à la fois.

Le fine-tuning fonctionne toujours en gelant le modèle de base et en ajoutant un petit ajustement entraînable à quelques unes de ses matrices de poids plutôt qu’en réentraînant tout le réseau, ce qui est ce qui rend la procédure possible sur un seul GPU grand public. Le rang de l’adaptateur, qui contrôle la taille de cet ajustement, est passé de 16 à 32, entraîné sur 580 questions au lieu de 380.




Figure 2 – Pipeline de fine-tuning. Seul le petit adaptateur est entraîné, les poids de base ne changent jamais, et aucune recherche documentaire n’intervient au moment de répondre.

Un changement fait spécifiquement ce mois a été l'ajout d'un petit ensemble de validation, 100 questions mises de côté avec une graine fixe, puisque l'essai précédent n'avait aucun moyen de savoir si le modèle apprenait vraiment à généraliser ou mémorisait simplement ses 380 exemples. Avec cet ensemble de validation en place, il est devenu possible de comparer le rang 16 au rang 32, l'attention seule à l'attention plus les couches de réseau direct, et différentes quantités de données d'entraînement, sur un signal qui reflète vraiment la généralisation plutôt que la seule perte d'entraînement.

Variante	n	Perte train	Perte val.
principal (rang 32)	580	0.834	0.679
rang 8	580	0.850	0.710
$n = 380$	380	0.966	0.860
$n = 786$	786	0.736	0.561
attn + MLP	580	0.527	0.416

Table 2 – Variantes de fine-tuning sélectionnées, trois époques chacune.

Plus de données d'entraînement aide de façon assez régulière, et laisser l'adaptateur toucher les couches de réseau direct en plus de l'attention baisse beaucoup la perte de validation, même si l'écart entre perte d'entraînement et perte de validation grandit aussi en même temps, ce qui signifie généralement que le modèle colle plus étroitement à ses données d'entraînement sans garantie que cela se transfère bien à de nouvelles questions. La configuration principale a aussi été répétée sur trois graines aléatoires différentes, donnant une perte d'entraînement de 0.843 ± 0.006 , assez stable en elle-même, même si la section suivante montre que la qualité des réponses réellement générées varie plus à travers ces mêmes trois graines que ce que la seule perte d'entraînement suggérerait.

4. Comparer quatre configurations correctement

La comparaison précédente utilisait trois configurations sur 50 questions et un seul essai. Ce mois une quatrième configuration a été ajoutée, le modèle fine-tuné combiné à la recherche documentaire, précisément parce qu'il n'y avait aucun moyen de savoir avec le dispositif précédent si les deux techniques aident sur la même faiblesse ou sur des faiblesses différentes, et la comparaison a été déplacée vers les 222 questions de test complètes avec un

traitement statistique convenable plutôt qu'un seul chiffre par configuration.

Les intervalles de confiance ont été obtenus en ré-échantillonnant les 222 questions avec remise un grand nombre de fois et en regardant combien le score moyen bouge à travers ces rééchantillonnages, ce qui donne une idée de combien un score donné aurait pu plausiblement être différent par le seul hasard. Chaque paire de configurations a aussi été testée deux fois pour vérifier une différence réelle, une fois avec un test sur les différences rééchantillonnées et une fois avec un test fondé sur les rangs qui fait moins d'hypothèses sur les données, et une correction a été appliquée pour tenir compte du fait de tester six paires à la fois plutôt que chaque comparaison comme si elle était la seule menée.

Config.	ROUGE-L	Intervalle 95%
Zero-shot	0.110	0.104 à 0.116
RAG	0.140	0.129 à 0.151
Fine-tune	0.147	0.136 à 0.160
Fine-tune + RAG	0.179	0.157 à 0.202

Table 3 – ROUGE-L avec intervalles de confiance bootstrap, jeu de test complet.




Figure 3 – ROUGE-L avec intervalles de confiance pour les quatre configurations.

Ajouter la recherche documentaire ou le fine-tuning seul bat clairement la base zero-shot dans les deux cas. La recherche documentaire et le fine-tuning pris séparément ne sont pas distinguables statistiquement l'un de l'autre, les deux tests s'accordent là dessus, ce qui dit déjà que les deux techniques sont plus proches en qualité globale que leurs scores bruts dans le tableau ne le suggéreraient à eux seuls. La comparaison entre le fine-tuning seul et la configuration combinée est le seul cas où les deux tests

ne sont pas d'accord, donc cette comparaison précise est traitée ici comme non tranchée plutôt que de choisir la réponse qui paraît la plus flatteuse.

Le résultat de fine-tuning du rapport précédent, mesuré sur 50 questions, était nettement plus haut que le 0.147 mesuré ici sur les 222 questions complètes, proche du bord supérieur de l'intervalle de confiance dans le tableau 3 sans vraiment tomber dedans. Ceci n'est pas traité comme une erreur à corriger, c'est une illustration assez directe de combien une estimation sur 50 questions peut bouger une fois mesurée sur un ensemble de questions plus grand et plus représentatif, ce qui est la raison principale pour laquelle toute cette comparaison a été refaite ce mois plutôt que réutilisée telle quelle.

5. D'où vient l'erreur restante

Une fois la recherche documentaire et la génération toutes les deux plus solides, la question suivante naturelle était laquelle des deux freinait encore le pipeline RAG. Une expérience a été montée pour répondre à cela directement, les vrais articles pertinents ont été placés directement dans le prompt sans passer par le moteur de recherche du tout, ce qui retire complètement l'erreur de recherche et montre ce que le générateur seul pourrait atteindre si la recherche était parfaite.

Condition	ROUGE-L	Exact match	Halluc.
Zero-shot	0.110	0.005	0.144
RAG (réel)	0.140	0.036	0.234
Contexte oracle	0.252	0.311	0.117

Table 4 – Expérience de contexte oracle, modèle de base dans tous les cas.

L'écart entre la recherche réelle et cette condition oracle est grand sur l'exactitude des citations, bien plus grand que l'écart entre la recherche réelle et l'absence totale de contexte, ce qui signifie que l'essentiel de ce qui manque actuellement vient de la recherche qui ne trouve pas le bon article plutôt que du modèle qui échouerait à utiliser un bon article une fois qu'il l'a. Un résultat n'était pas attendu au départ, le modèle hallucine davantage avec la recherche réelle qu'avec aucun contexte du tout, comme si un article plausible mais faux invitait à une invention plus confiante que de n'avoir rien du tout. Le même protocole a aussi été lancé une fois sur Qwen2.5-7B-Instruct à la place de Mistral, sur-

tout pour vérifier que ce n'était pas une particularité d'un seul modèle, et le même comportement est apparu là aussi, la recherche documentaire améliore la qualité globale tout en doublant à peu près le taux d'hallucination.

La profondeur de recherche a aussi été vérifiée, puisque le pipeline utilisait cinq articles retrouvés de façon assez arbitraire. Essayer un, trois et dix articles sur un plus petit échantillon a montré une qualité maximale autour de trois, dix articles ne faisant pas mieux qu'un seul malgré bien plus de texte, ce qui suggère qu'au delà d'un certain point le contexte supplémentaire rend l'article pertinent plus difficile à repérer plutôt que plus facile.

6. Si le système connaît ses propres limites

Aucune des mesures ci-dessus ne dit rien sur une question à laquelle le système devrait simplement refuser de répondre. Un ensemble de 50 questions de ce type a été construit ce mois, certaines sans aucun contenu juridique, certaines sur un système juridique que BSARD ne couvre pas, et certaines faisant référence à un article qui n'existe plus dans l'index, pour voir si l'une ou l'autre configuration reconnaîtrait cela plutôt que de répondre quand même.

Config.	Abstention correcte
Zero-shot	0.0%
RAG	2.0%

Table 5 – Abstention correcte sur 50 questions hors de portée.

Le système ne refuse presque jamais de répondre. Même pour une question qui n'a rien à voir avec le droit, il produit une réponse à l'air confiant, numéros d'article inventés inclus, dans presque tous les cas. C'est l'une des faiblesses les plus nettes trouvées ce mois et une de celles qu'aucune des deux techniques ne corrige d'elle même.

7. Mesurer la qualité sous deux angles

Le recouvrement lexical avec un texte de référence et le fait qu'une réponse traite vraiment la question posée sont deux choses différentes, et il semblait préférable de les mesurer séparément plutôt

que de les fondre en un seul score. Une mesure déterministe a été ajoutée qui vérifie combien d’entités nommées, de nombres et de détails similaires dans la réponse générée apparaissent aussi dans le texte de référence, donnant une idée de l’ancrage factuel sans avoir besoin d’un autre modèle pour en juger¹. Séparément, un modèle de langage indépendant, Phi-3.5-mini-instruct, a été utilisé pour juger si chaque réponse traite bien ce qui était vraiment demandé, en notant chaque réponse plusieurs fois plutôt qu’une seule puisqu’un seul jugement d’un modèle de langage n’est pas très stable.

Config.	Fidélité	Pertinence /5
Zero-shot	0.054	5.00
RAG	0.295	4.85
Fine-tune	0.298	4.73
Fine-tune + RAG	0.324	4.62

Table 6 – Fidélité au texte de référence et pertinence jugée.

Le score moyen de pertinence reste haut et presque plat à travers les configurations, mais regarder la distribution complète plutôt que la seule moyenne montre une part petite mais qui grandit régulièrement de réponses jugées clairement hors sujet en allant du zero-shot vers la configuration combinée. Lu avec la lecture qualitative d’une section plus loin, cela suggère que la recherche documentaire et le fine-tuning éloignent parfois la réponse de la question réellement posée, un effet réel mais plus petit que l’écart d’ancrage des citations décrit plus haut.

8. Ce qui rend une question difficile

Deux explications possibles pour lesquelles certaines questions obtiennent de meilleures réponses que d’autres ont été vérifiées directement plutôt que supposées, la longueur de la question et le nombre d’articles de loi vraiment nécessaires pour y répondre. La longueur de la question s’est avérée n’avoir presque aucun lien avec la qualité de la réponse. Le nombre d’articles nécessaires, en revanche, corrèle clairement et de façon constante avec une qualité plus basse dans chaque configuration, donc la longueur était la mauvaise chose à supposer importante et le vrai

1. Cette séparation entre une mesure d’ancrage déterministe et un juge indépendant pour ce qui est vraiment subjectif suit l’approche utilisée par Bouvard, Ciancone, Gourru et Schaeffer pour une comparaison similaire entre RAG et fine-tuning (APIA 2024), réimplémentée ici.

facteur est combien de règles séparées doivent être combinées dans une seule réponse.




Figure 4 – ROUGE-L regroupé par nombre d’articles requis.

La qualité reste globalement stable pour les questions nécessitant un à trois articles et chute nettement dès que quatre ou plus sont nécessaires, dans chaque configuration sans exception, et ni la recherche documentaire ni le fine-tuning ne corrige cela d’eux mêmes.

9. Un adaptateur spécialiste d’un domaine

Regarder les résultats découpés par catégorie juridique suggérerait une question naturelle, un adaptateur entraîné sur un seul domaine ferait-il mieux sur ce domaine qu’un adaptateur généraliste. Un adaptateur spécialiste a été entraîné sur le sous-ensemble des questions d’entraînement concernant le Code Civil, avec moins d’exemples que l’adaptateur généraliste puisque ce sous-ensemble est plus petit, et comparé au généraliste sur les mêmes questions de test.

Le résultat est ressorti mitigé plutôt que comme une victoire nette pour la spécialisation. Sur son propre domaine le spécialiste est légèrement meilleur en recouvrement lexical mais hallucine nettement plus, et combiné à la recherche documentaire il fait moins bien que le généraliste dans les deux domaines tout en hallucinant moins dans les deux. Comme le spécialiste a été entraîné sur moins d’exemples que le généraliste, cette comparaison mélange l’effet de restreindre le domaine avec l’effet d’avoir simplement moins de données d’entraînement, et les résultats de fine-tuning plus haut dans ce rapport montrent déjà que moins d’exemples à eux seuls font baisser la qualité. Cette expérience ne tranche

pas vraiment si la spécialisation par domaine aide, elle montre surtout qu’un test équitable de cette idée demande des tailles d’entraînement comparables.

10. Confronter les résultats au jugement humain

Toute mesure jusqu’ici est automatique, et un score automatique peut être cohérent avec lui même tout en ne correspondant pas à ce qu’une personne préférerait vraiment lire. Les deux auteurs, avec un troisième annotateur dont la collecte de données est encore en cours, ont comparé à l’aveugle la configuration avec recherche documentaire et la configuration fine-tunée sur 60 questions, sans savoir quel côté était lequel.

Annotateur	Préfère RAG	Préfère fine-tune
Annotateur 1	70.0%	10.0%
Annotateur 2	55.0%	8.3%

Table 7 – Préférence par paire à l’aveugle, 60 questions communes.

L’accord entre les deux annotateurs sur les questions communes était modéré plutôt que fort, ce qui est rapporté honnêtement plutôt que supposé acquis, et discuté un peu plus loin. Même ainsi, les deux annotateurs ont préféré clairement et indépendamment la configuration avec recherche documentaire à la configuration fine-tunée, par une marge large. Ceci est en tension réelle avec la comparaison automatique précédente sur 50 questions, qui avait placé le modèle fine-tuné devant sur le recouvrement lexical. Plutôt que d’essayer d’expliquer cette tension, elle est prise ici comme le signe le plus clair ce mois qu’une comparaison lexicale sur petit échantillon et un jugement humain à l’aveugle sur les deux mêmes systèmes ne vont pas toujours dans le même sens, ce qui est la raison pour laquelle les deux sont maintenant mesurés côte à côte.

11. Ce que la lecture des réponses a montré

Au delà des chiffres, lire directement les réponses annotées a fait ressortir quelques schémas qui méritent d’être décrits avec leurs propres mots. L’erreur la plus courante est une inversion de rôles juridiques,

une obligation attribuée à la mauvaise partie, souvent sur des paires de questions qui ne diffèrent que d’un mot, marié contre cohabitant légal par exemple, où le bon article diffère d’une façon subtile facile à manquer aussi bien pour la recherche que pour la génération. Du texte de loi inventé apparaît aussi assez souvent, et étant donné que l’hallucination ne disparaît pas complètement même sous la condition de contexte oracle, une partie au moins de cela semble être une tendance générale du modèle de base plutôt que purement une conséquence d’une mauvaise recherche. Un nombre plus petit de réponses dérive simplement loin de la question posée, généralement quand un passage retrouvé est proche du sujet sans vraiment répondre à ce qui était demandé. Un dernier schéma, du texte répété ou coupé dans certaines réponses, ressemble à un problème de réglage du décodage plutôt qu’à une limite du modèle, puisque la génération n’utilise actuellement aucune pénalité de répétition.

12. Difficultés pratiques ce mois

Comme dans le rapport précédent, les problèmes techniques les plus longs à résoudre sont listés ici brièvement. Aucun ensemble de validation n’existait pour le fine-tuning avant ce mois, ce qui rendait impossible de distinguer un modèle qui généralise d’un modèle qui mémorise sur quelques centaines d’exemples, et un petit ensemble de validation fixe a été ajouté spécifiquement pour combler ce manque.

13. Ce qui reste avant le rapport final

Ce rapport est le dernier rapport mensuel avant le rendu final, prévu le 20 août. La collecte de données du troisième annotateur doit être terminée. Il reste enfin à construire l’interface du chatbot final et à terminer la rédaction du rapport final.

Références

- [1] E. J. Hu et al. *LoRA : Low-Rank Adaptation of Large Language Models*. ICLR 2022. arXiv :2106.09685.
- [2] T. Detrmers et al. *QLoRA : Efficient Finetuning of Quantized LLMs*. NeurIPS 2023. arXiv :2305.14314.

- [3] P. Lewis et al. *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*. NeurIPS 2020. arXiv :2005.11401.
- [4] C. Bouvard, M. Ciancone, A. Gourru, M. Schaeffer. *Derby LLM : Évaluation comparative des approches RAG et fine-tuning*. APIA 2024. hal-04638460.
- [5] A. Louis, G. Spanakis. *A Statutory Article Retrieval Dataset in French*. ACL 2021. arXiv :2108.11792.
- [6] T. Zhang, V. Kishore, F. Wu, K. Q. Weinberger, Y. Artzi. *BERTScore : Evaluating Text Generation with BERT*. ICLR 2020. arXiv :1904.09675.
- [7] O. Ovadia, M. Brief, M. Mishaeli, O. Elisha. *Fine-Tuning or Retrieval? Comparing Knowledge Injection in LLMs*. arXiv :2312.05934, 2023.